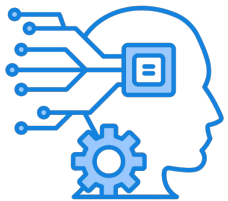
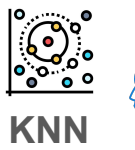
Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA



Aprendizado de Máquina - Supervisionado



- K-Nearest Neighbors (KNN)
  - algoritmo de aprendizado supervisionado usado para classificação
  - Para classificar uma nova amostra, o KNN procura as K amostras mais próximas dela no conjunto de treinamento e verifica a classe predominante entre essas vizinhas
  - O K representa quantos vizinhos serão considerados

Aprendizado de Máquina - Supervisionado

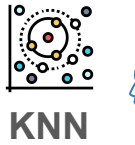


➔ K-Nearest Neighbors (KNN)

- Imagine duas características
  - comprimento da sépala: aproximadamente 4–8
  - alguma outra variável: aproximadamente 0–1000

- A segunda variável poderia dominar a distância. Por isso, frequentemente usamos normalização ou padronização antes do KNN

Aprendizado de Máquina - Supervisionado

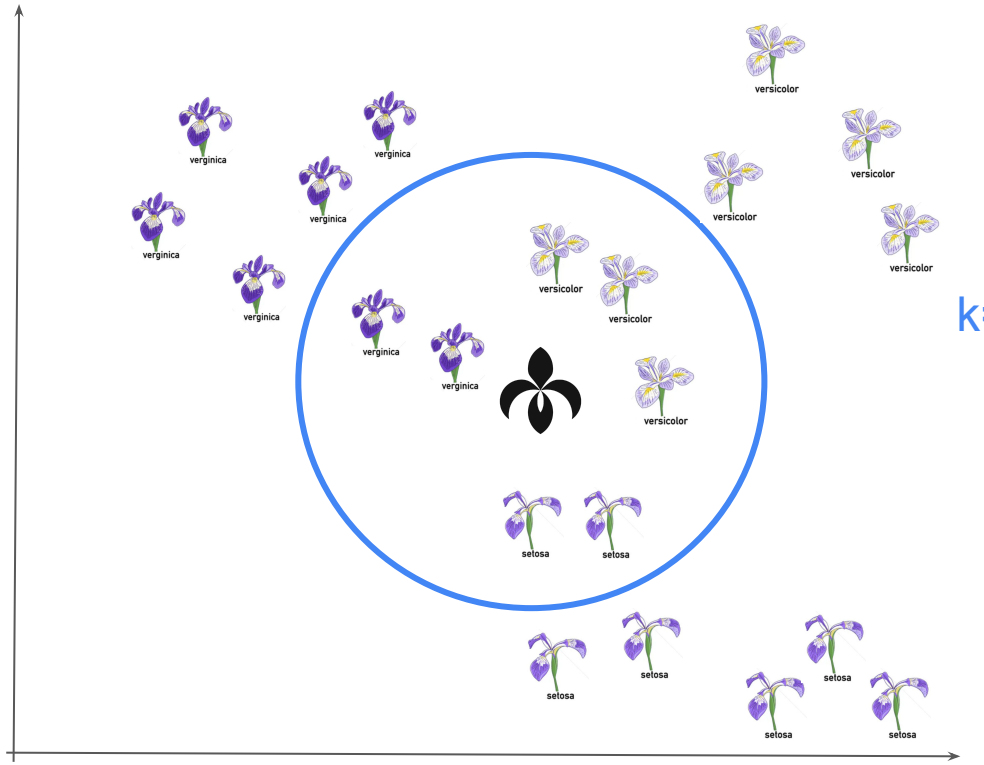


➔ K-Nearest Neighbors (KNN)

- Usando pesos (weights)
  - É possível atribuir pesos, de tal forma que vizinhos mais próximos exercem maior influência na classificação

Aprendizado de Máquina - Supervisionado

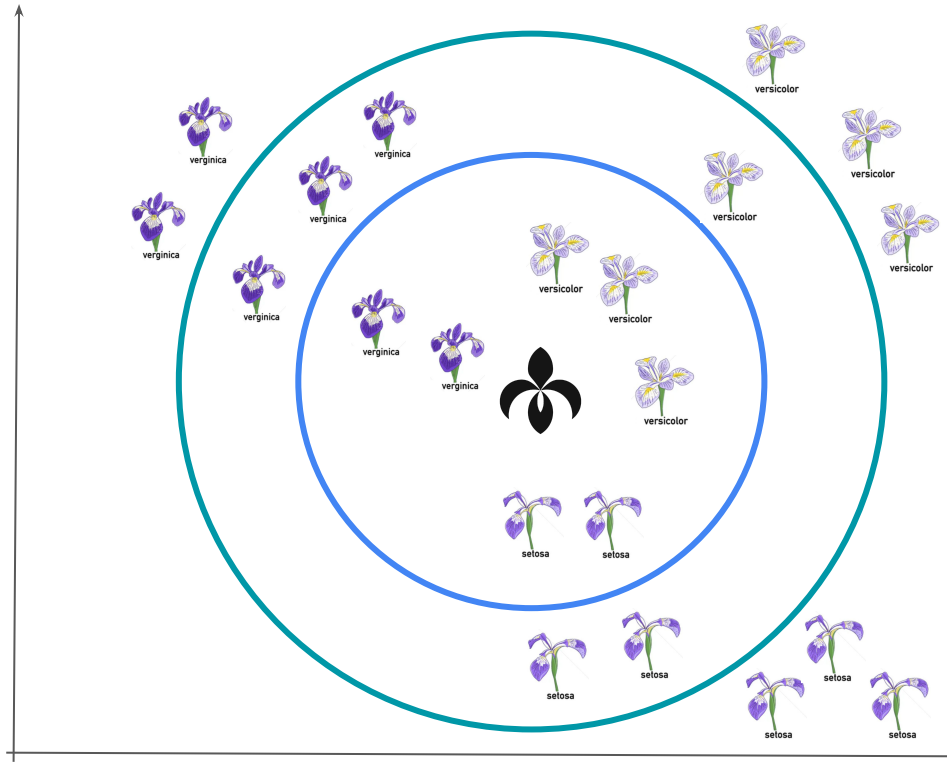
KNN



k=3 → Versicolor

Aprendizado de Máquina - Supervisionado

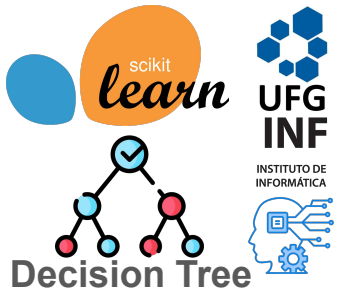
KNN



k=3 → Versicolor

k=5 → Virgínica

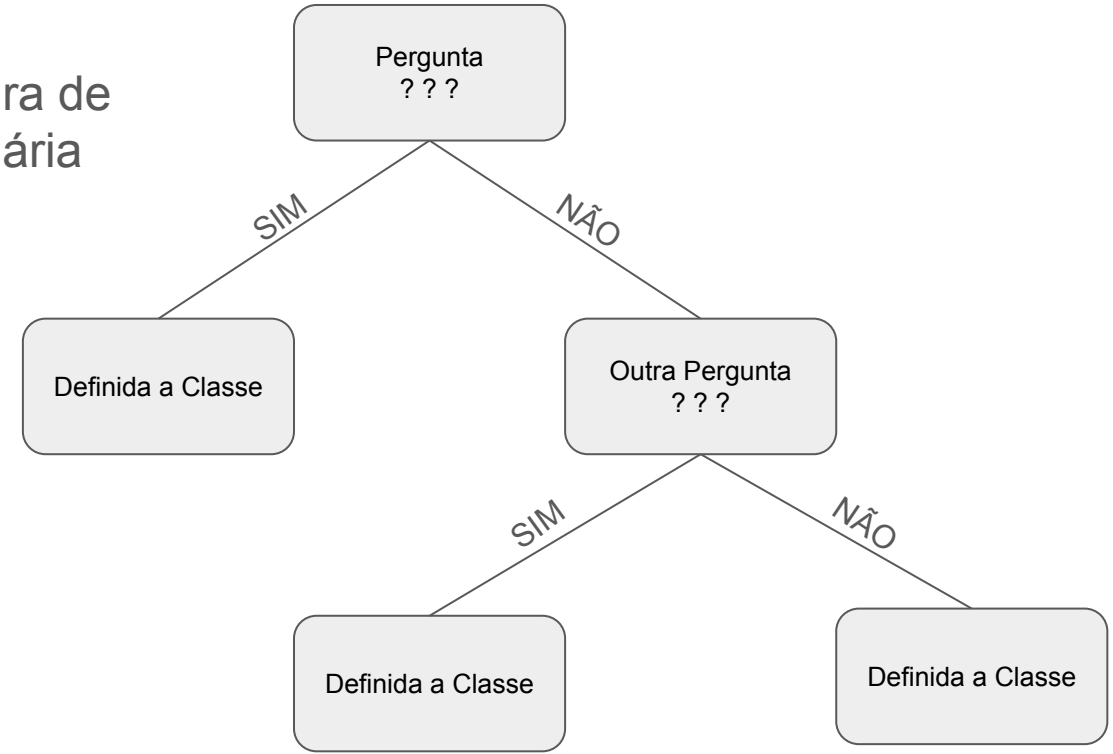
Aprendizado de Máquina - Supervisionado



- Decision Tree
  - Não foi criada por uma única pessoa em um único ano. O conceito evoluiu através de várias pesquisas em estatística, reconhecimento de padrões e aprendizado de máquina
  - Os trabalhos mais importantes aplicando este algoritmo aparecem entre 1960 e 1970
  - O algoritmo divide os dados sucessivamente através de perguntas até chegar a uma decisão

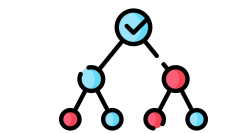
Aprendizado de Máquina - Supervisionado

Utiliza a estrutura de uma Árvore Binária



Decision Tree

Classificação com dados do Kaggle



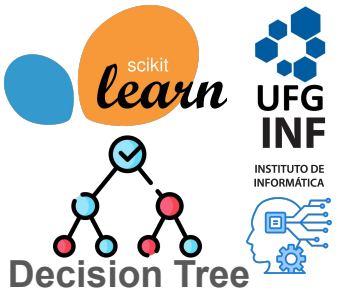
- *Public Health Dataset* (acessado em 10/08/2026)
  - https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_02A.csv
```

Heart Disease Dataset Attribute Description **1.190 amostras**

S.No.	Attribute	Code given	Unit	Data type
1	age	Age	in years	Numeric
2	sex	Sex	1, 0	Binary
3	chest pain type	chest pain type	1,2,3,4	Nominal
4	resting blood pressure	resting bp s	in mm Hg	Numeric
5	serum cholesterol	cholesterol	in mg/dl	Numeric
6	fasting blood sugar	fasting blood sugar	1,0 > 120 mg/dl	Binary
7	resting electrocardiogram results	resting ecg	0,1,2	Nominal
8	maximum heart rate achieved	max heart rate	71–202	Numeric
9	exercise induced angina	exercise angina	0,1	Binary
10	oldpeak =ST	oldpeak	depression	Numeric
11	the slope of the peak exercise ST segment	ST slope	0,1,2	Nominal
12	class	target	0,1	Binary

Aprendizado de Máquina - Supervisionado



➔ Como o algoritmo "Aprende" ?

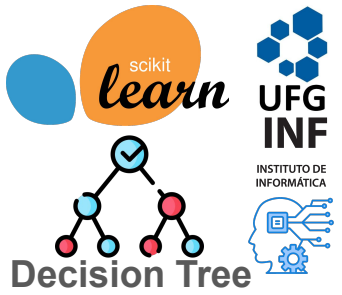
- ◆ O algoritmo procura perguntas que consigam separar bem as classes

Idade	*Oldpeak	FC máxima	Doença
45	0.0	170	Não
50	0.5	160	Não
52	0.8	155	Não
60	2.0	130	Sim
65	2.5	120	Sim
70	3.0	110	Sim

* Depressão do segmento ST induzida pelo exercício em relação ao ECG em repouso

- idade <= 54.5 ?
- oldpeak <= 1.2 ?
- frequência cardíaca <= 140 ?

Aprendizado de Máquina - Supervisionado



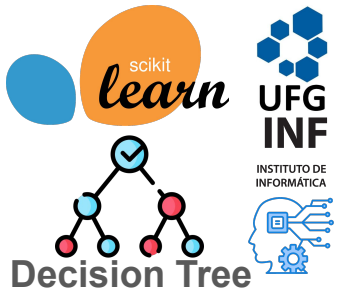
- Como o algoritmo "Aprende" ?
  - O algoritmo procura uma pergunta que consiga separar bem as classes

Idade	*Oldpeak	FC máxima	Doença
45	0.0	170	Não
50	0.5	160	Não
52	0.8	155	Não
60	2.0	130	Sim
65	2.5	120	Sim
70	3.0	110	Sim

IF característica <operador> valor

  - Qual característica / valor conseguiria separar bem as linhas da tabela ?
  - Qual característica avaliar (idade, Oldpeak, FC Máxima, outra) ?

Aprendizado de Máquina - Supervisionado

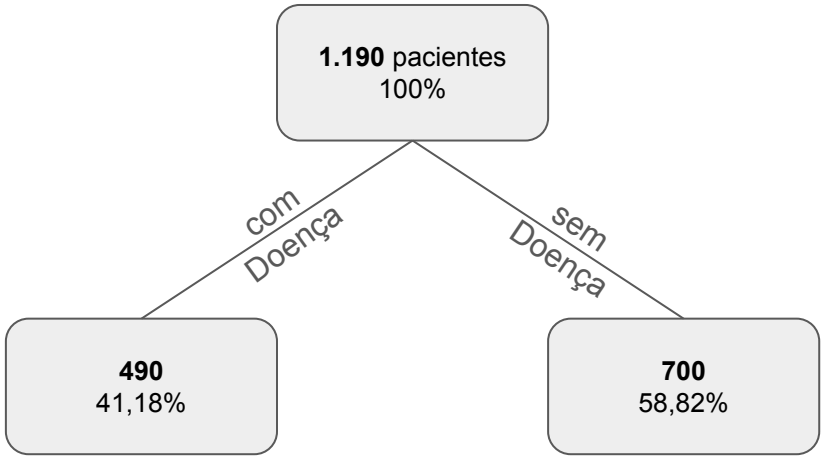


- Imagine que o dataset possui várias características
  - O algoritmo procura uma pergunta que consiga separar bem as classes

Característica 1	...	Característica n	Doença
700 paciente que não possuem a "doença"			Não
			Não
			Não
400 pacientes com a "doença"			Sim
			Sim
			Sim

  - Qual característica / valor conseguiria separar bem as linhas da tabela ?

Aprendizado de Máquina - Supervisionado

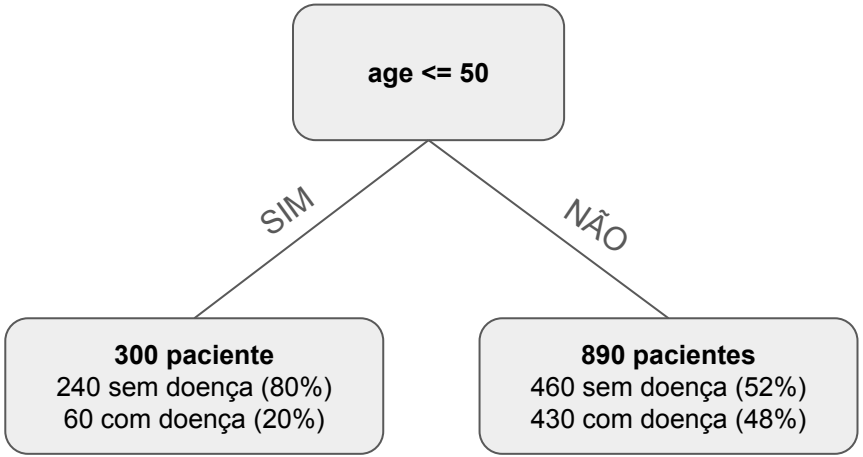


➔ Desejamos utilizar o Decision Tree para separar/classificar os pacientes com doença e sem doença

- O algoritmo vai avaliar as características do dataset
  - age, sex, chest pain type, resting bp s, cholesterol, fasting blood sugar, resting ecg, max heart rate, exercise angina, oldpeak, ST slope

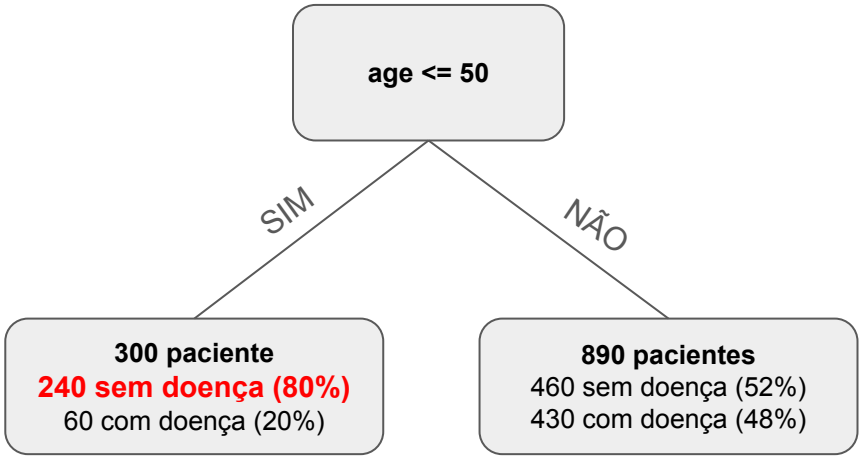
Aprendizado de Máquina - Supervisionado

➔ Suponha que após o teste com a característica age, os dados ficaram assim:



Aprendizado de Máquina - Supervisionado

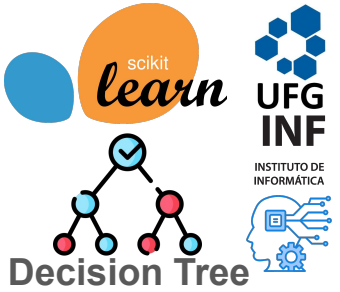
➔ Intuitivamente, podemos dizer que a divisão parece ter melhorado, ao menos para um dos grupo



➔ Um dos grupos ficou significativamente **mais concentrado** em uma classe

➔ **Quanto esta opção melhorou na separação dos com doença e sem doença ???**

Aprendizado de Máquina - Supervisionado



- Coeficiente de GINI

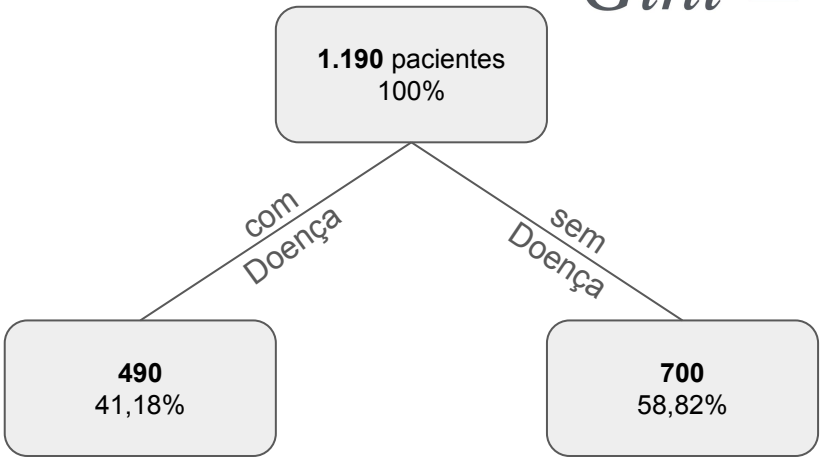
$$Gini = 1 - \sum_{i=1}^{K} p_i^2$$

  - QUANTO as classes foram bem ou mal separadas ?
  - Calculamos o coeficiente a cada pergunta (separação aplicada)

Aprendizado de Máquina - Supervisionado

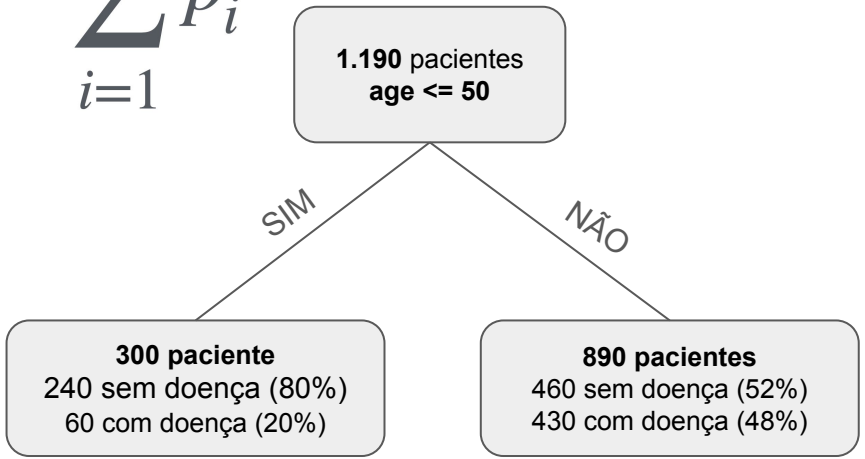
Decision Tree

$$Gini = 1 - \sum_{i=1}^{K} p_i^2$$



$Gini = 1-(0{,}4118^2+0{,}5882^2)$

***Gini* = 0,4844**



$Gini_S = 1-(0{,}8^2+0{,}2^2)$
$Gini_S = 0{,}36$

$Gini_N = 1-(0{,}5169^2+0{,}4831^2)$
$Gini_N = 0{,}4994$

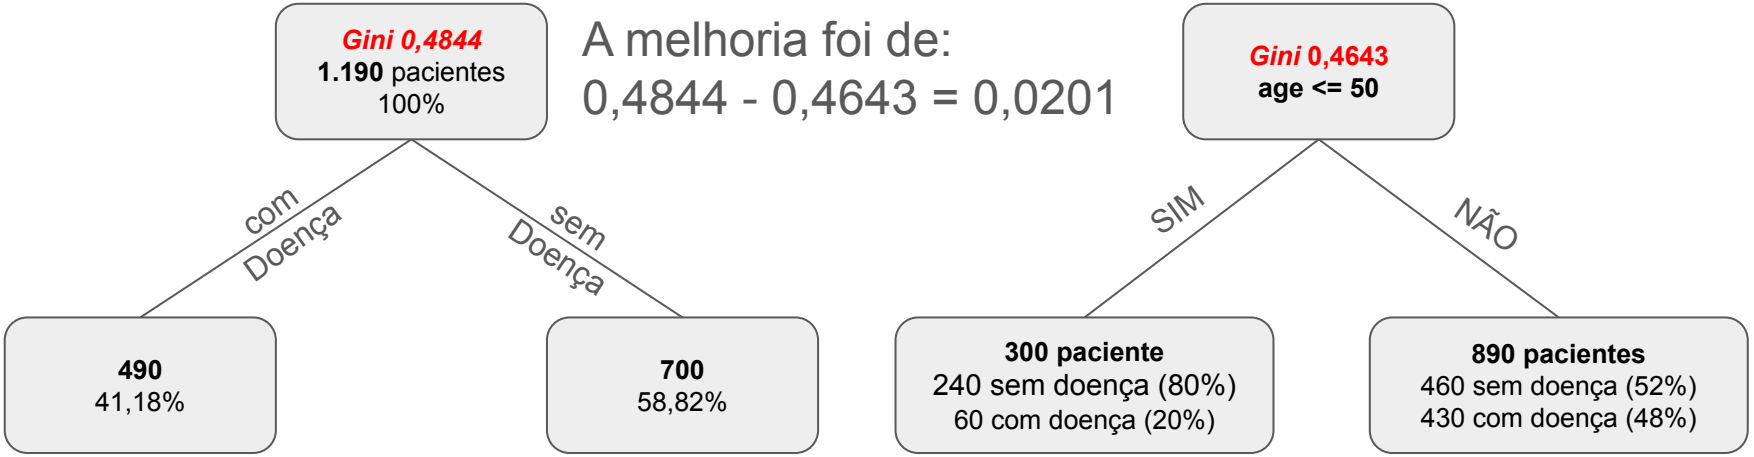
$Gini = [(300/1190) \times 0{,}36] + [(890/1190) \times 0{,}4994] / 2$

***Gini* = 0,4643**

Aprendizado de Máquina - Supervisionado

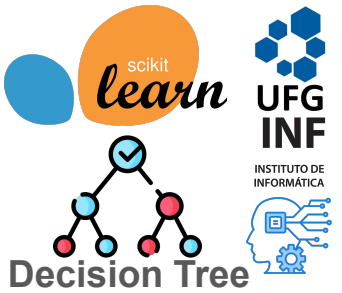
$$Gini = 1 - \sum_{i=1}^{K} p_i^2$$

Gini Maior = Mais misturadas as amostras
Gini Menor = Menos misturadas as amostras



O algoritmo Decision Tree repete a operação para age <= 40, 45, 50, 55, 60, …

Aprendizado de Máquina - Supervisionado



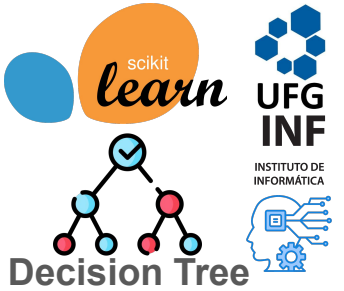
- O algoritmo Decision Tree repete esta operação para:
  - age → Range (1,120)
  - oldpeak → Range (0.2, 5.0)
  - cholesterol → Range (100, 500)
  - etc.

isto se repetirá milhares de vezes

- Após as repetições teremos algo como:

Pergunta	*Gini* após divisão
age <= 45	0,472
age <= 50	0,464
age <= 55	0,451
oldpeak <= 0,8	0,430
oldpeak <= 1,2	0,390
oldpeak <= 2,0	0,421
max_hr <= 130	0,445

Aprendizado de Máquina - Supervisionado



- ➔ O algoritmo Decision Tree repete esta operação para:
  - age → Range (1,120)
  - oldpeak → Range (0.2, 5.0)
  - cholesterol → Range (100, 500)
  - etc.
- ➔ Após as repetições teremos algo como:

Pergunta	*Gini* após divisão
age <= 45	0,472
age <= 50	0,464
age <= 55	0,451
oldpeak <= 0,8	0,430
oldpeak <= 1,2	**0,390**
oldpeak <= 2,0	0,421
max_hr <= 130	0,445

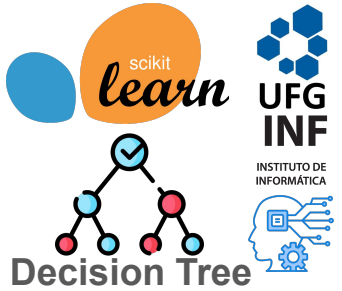
A pergunta/característica/valor que melhor separa as classes é:

- oldpeak <= 1,2

Portanto esta será a questão da raiz de nossa Decision Tree

A cada nível que avança na Decision Tree a operação se repete

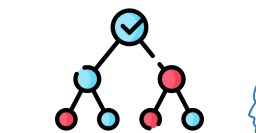
Aprendizado de Máquina - Supervisionado



- ➔ O algoritmo Decision Tree possui as seguintes métricas para separação das classes:
  - ◆ Coeficiente de Gini
    - mede o quanto as classes estão misturadas em um grupo, e a árvore procura a divisão que mais reduz essa mistura
  - ◆ Critério de Entropia
    - mede o grau de desordem ou incerteza das classes em um grupo, e a árvore procura a divisão que mais reduz essa desordem
  - ◆ Log Loss
    - mede o quanto as probabilidades previstas estão próximas das classes reais, penalizando fortemente previsões probabilísticas muito erradas

Aprendizado de Máquina - Supervisionado

➔ Avaliando a classificação do Decision Tree na prática

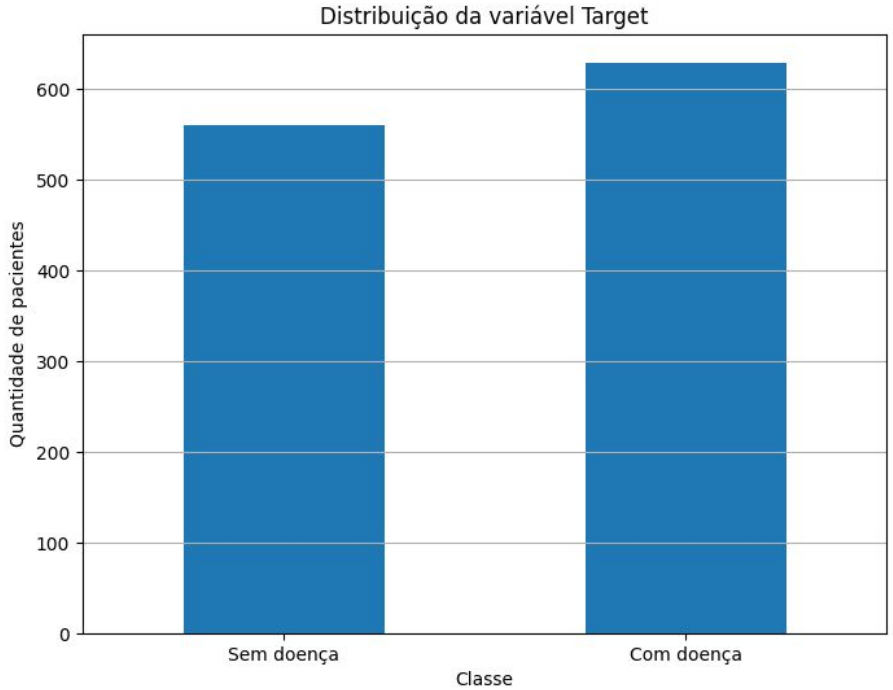



```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_02A.py
```

```
Caminho e nome do arquivo (Precisa de Hardware com mais recursos para executar)
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_02B.py
```

Aprendizado de Máquina - Supervisionado

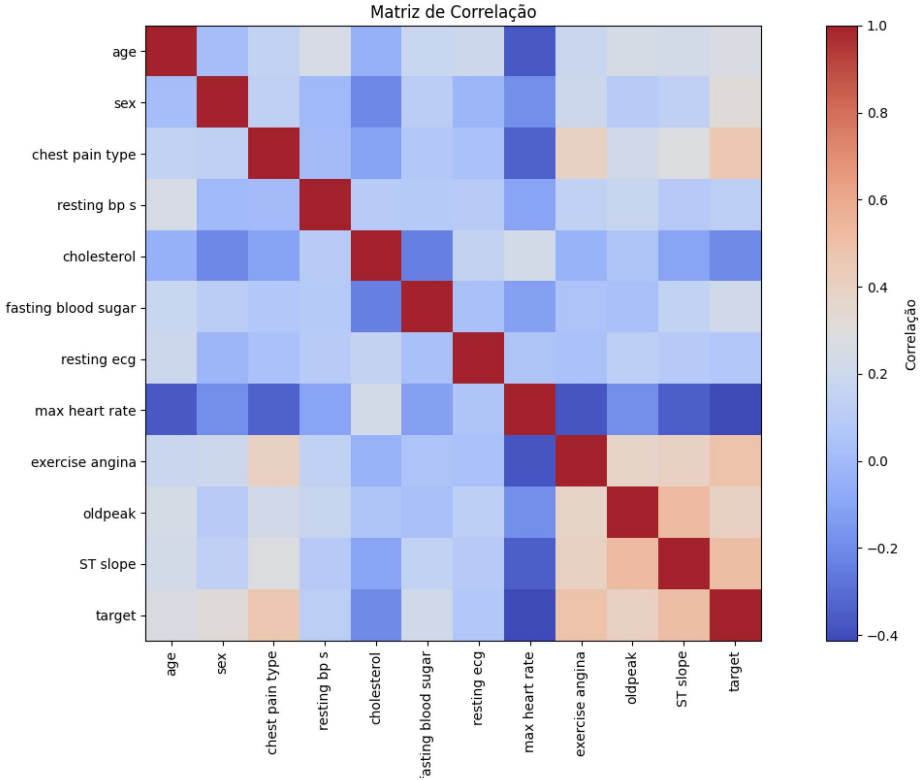
➔ Avaliando a classificação do Decision Tree na prática



Antes de treinar um algoritmo de classificação, precisamos conhecer a distribuição da variável alvo, pois isso nos permite saber se as classes estão equilibradas, identificar possíveis problemas de desbalanceamento e interpretar corretamente as métricas de desempenho do modelo

Aprendizado de Máquina - Supervisionado

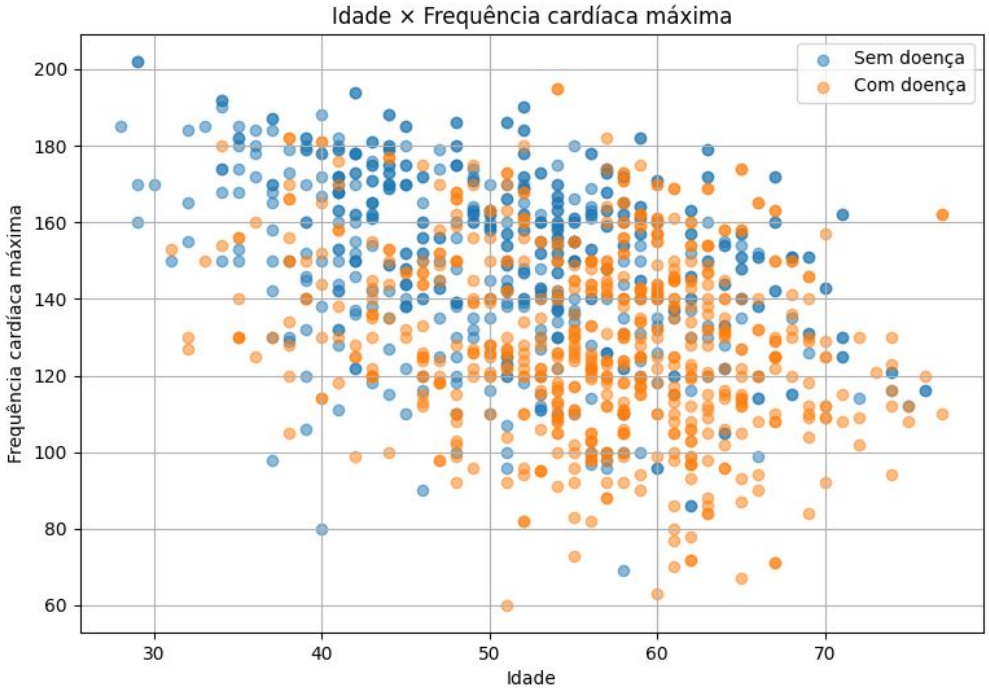
➔ Avaliando a classificação do Decision Tree na prática



Quando existe uma correlação positiva de duas características, significa que existe uma tendência de, quando uma aumenta, a outra também aumentar

Aprendizado de Máquina - Supervisionado

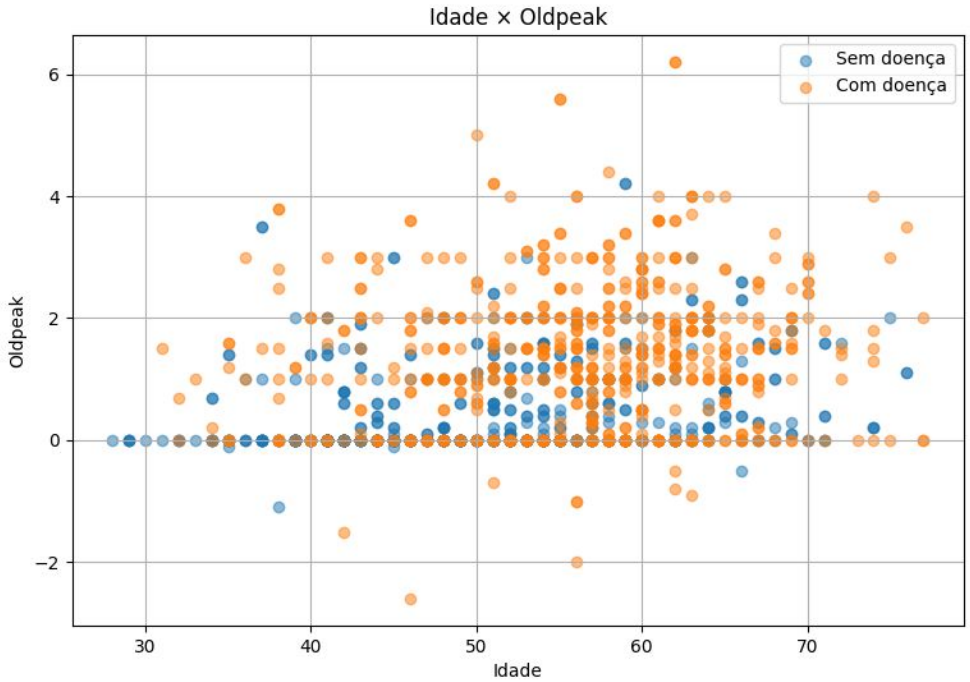
➔ Avaliando a classificação do Decision Tree na prática



Exploratório
Apenas para entender a distribuição das amostra segundo duas características

Aprendizado de Máquina - Supervisionado

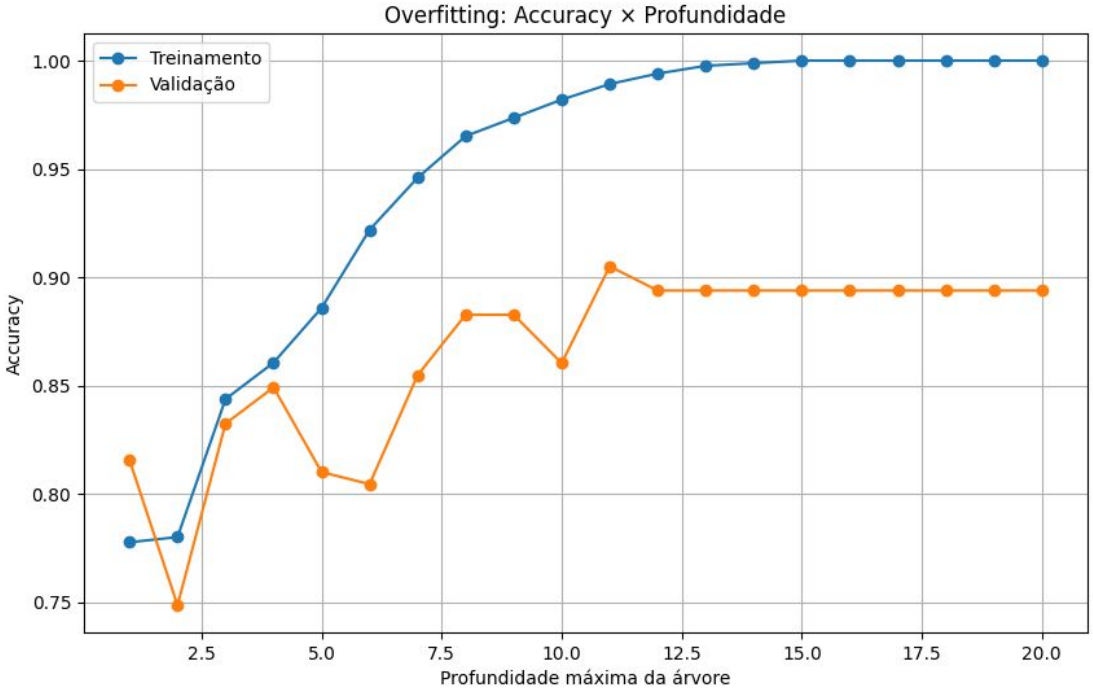
➔ Avaliando a classificação do Decision Tree na prática



Exploratório
Apenas para entender a distribuição das amostra segundo duas características

Aprendizado de Máquina - Supervisionado

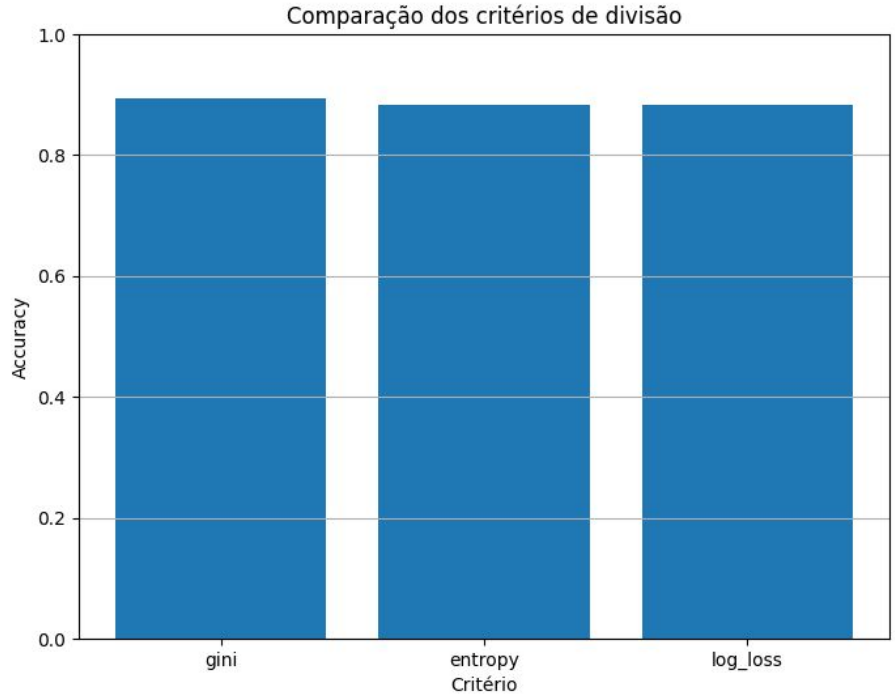
➔ Avaliando a classificação do Decision Tree na prática



Acurácia à medida de aumentam os níveis da Decision Tree

Aprendizado de Máquina - Supervisionado

➔ Avaliando a classificação do Decision Tree na prática

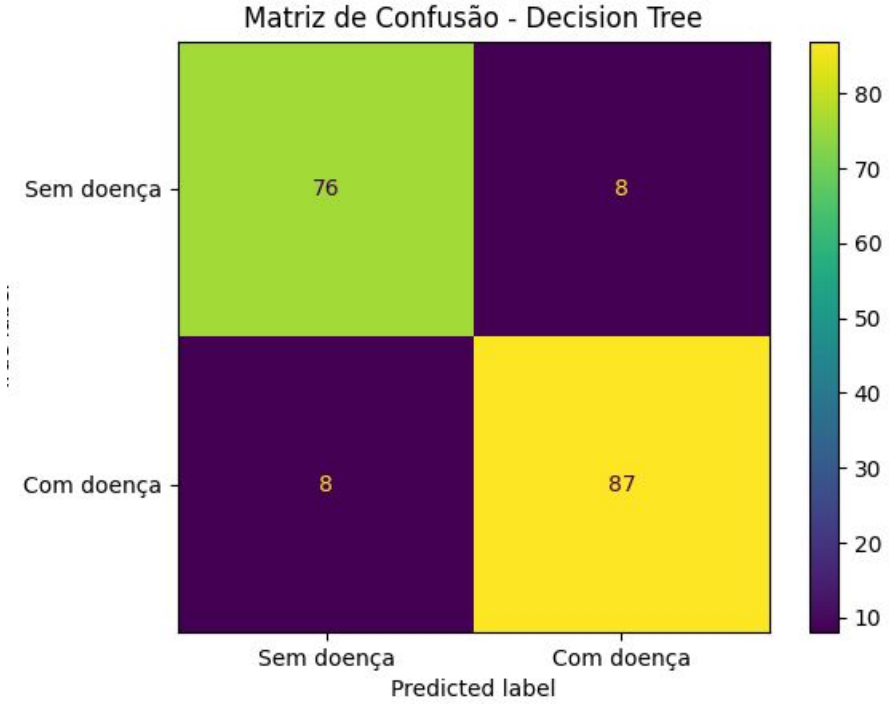


Qual dos 3 critérios de separação das amostras divide melhor

gini: 89.39%
entropy: 88.27%
log_loss: 88.27%

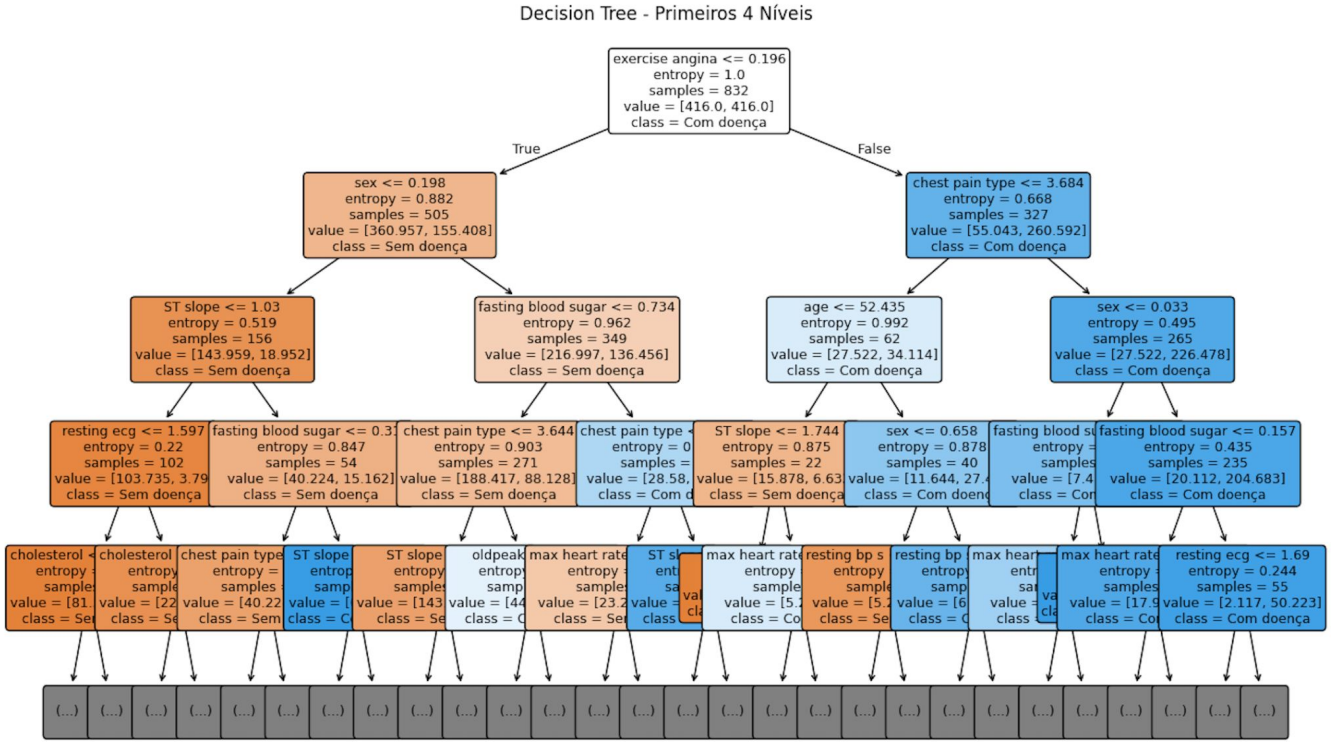
Aprendizado de Máquina - Supervisionado

➔ Avaliando a classificação do Decision Tree na prática



Aprendizado de Máquina - Supervisionado

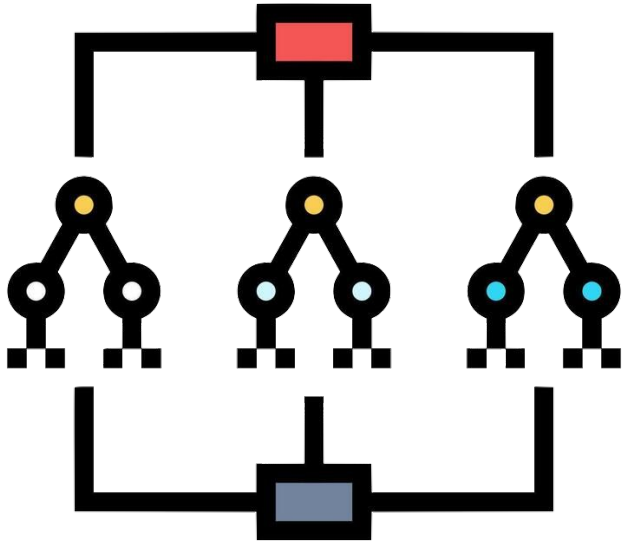
➔ Avaliando a classificação do Decision Tree na prática



Decision Tree

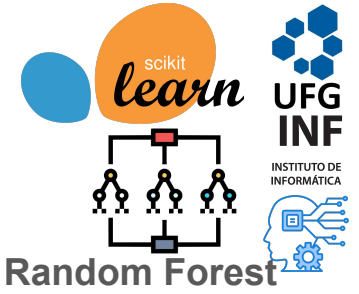
Aprendizado de Máquina - Supervisionado

➔ Random Forest → Talvez um dos mais utilizados



Random Forest

Aprendizado de Máquina - Supervisionado



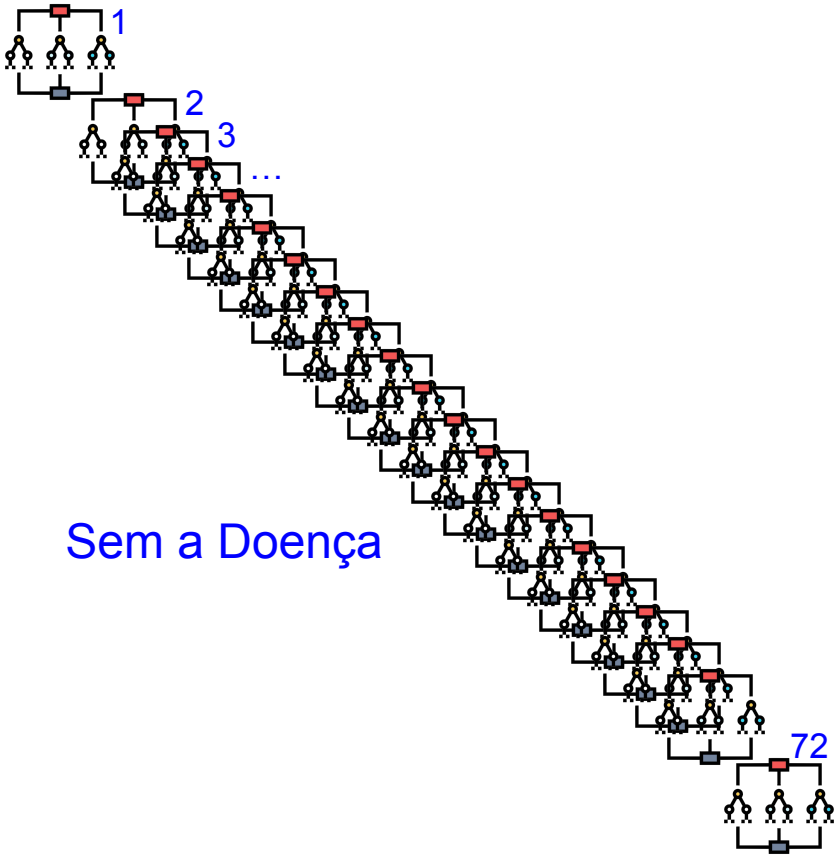
➔ Random Forest

- Imagine a possibilidade de criarmos várias Decision Tree para um único problema de classificação o *Public Health Dataset* por exemplo

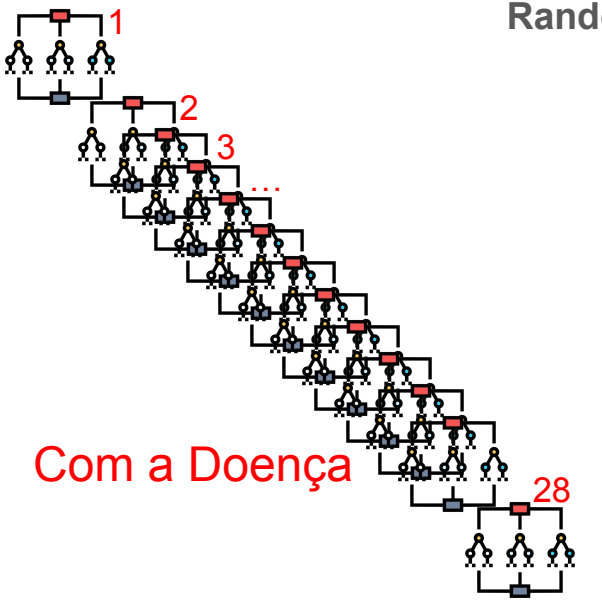
- Enquanto o *Decision Tree* trabalha com 1 (uma) árvore binária o Random Forest pode trabalhar com uma centena de Decision Tree

- Então poderíamos ter 100 árvores classificando os dados dos pacientes. Imagine que conforme os dados de entrada **72 árvores** apontaram que é um paciente **sem a doença** enquanto **28 árvores** apontação que o paciente está **com a doença**

Aprendizado de Máquina - Supervisionado



Sem a Doença

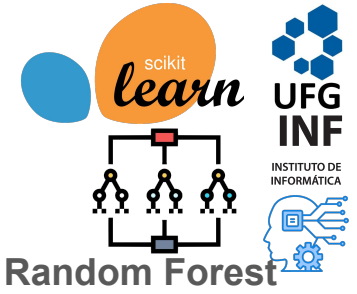


Com a Doença

Supondo que a entrada nesta rede de Árvores chegou a esta classificação
Inferência: Sem a Doença

Random Forest

Aprendizado de Máquina - Supervisionado

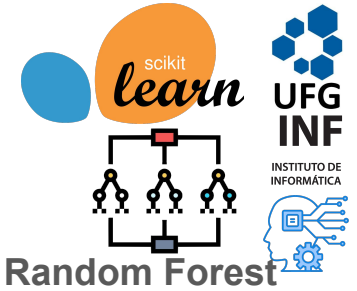


- ➔ Se todas são Decision Trees, por que elas dariam respostas diferentes?
  - ◆ Porque a Random Forest não constrói 100 árvores exatamente iguais
    - Aleatoriedade de amostras
      - Diferentes amostras para treinar cada árvore
    - Aleatoriedade de características
      - Subconjunto diferente de características para cada árvore

- ➔ Random Forest é um conjunto de várias Decision Trees independentes e diversificadas

Aprendizado de Máquina - Supervisionado

➔ Random Forest

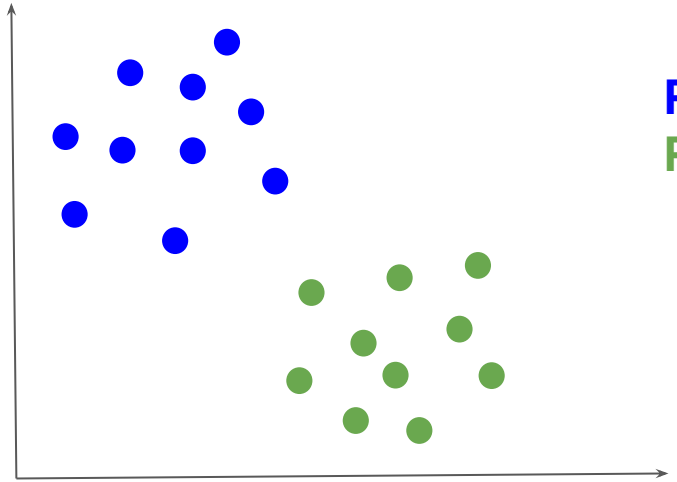



```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_03.py
```

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- O SVM procura uma fronteira de decisão que separe as classes deixando a maior margem possível entre elas



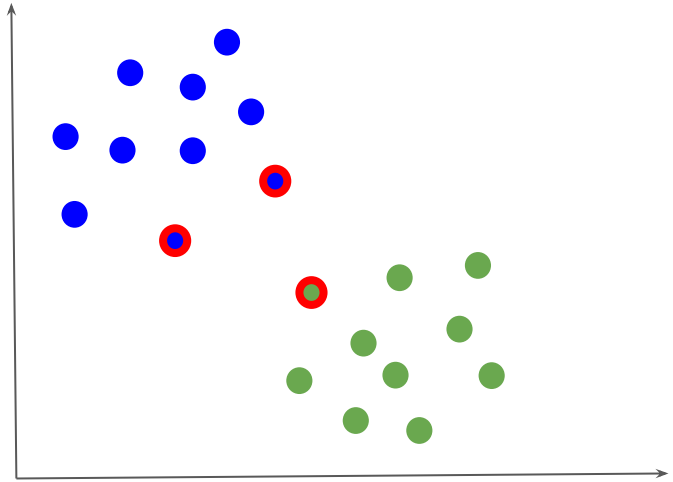
Pessoas sem a Doença

Pessoas com a Doença

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

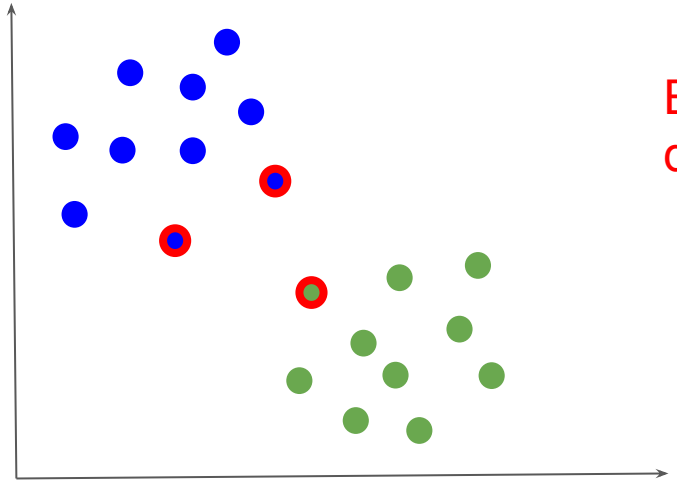
- O primeiro passo é encontrar o "limites" entre as classes, ou seja, os pontos mais próximos que sejam linearmente separáveis



Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- O primeiro passo é encontrar o "limites" entre as classes, ou seja, os pontos mais próximos que sejam linearmente separáveis

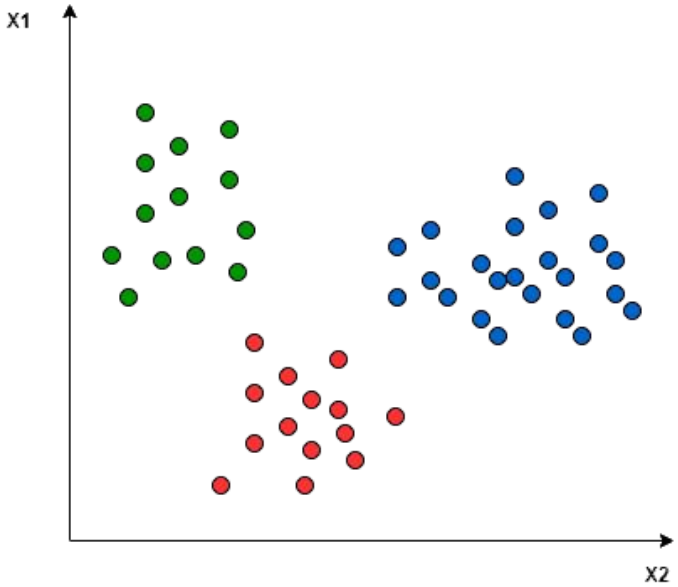


Estes pontos são chamados de vetores de suporte

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

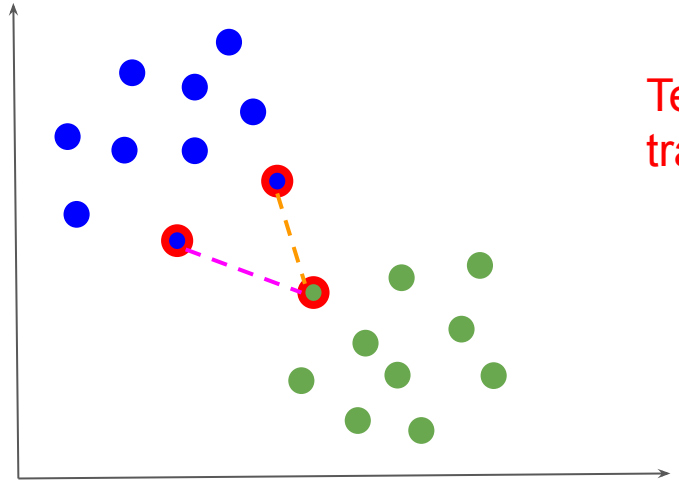
- Em dataset maiores e com os dados mais "misturados" é possível encontrar muitas amostras como estas em destaque



Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- Tendo encontrado os vetores de suporte, é possível traçar uma reta entre eles

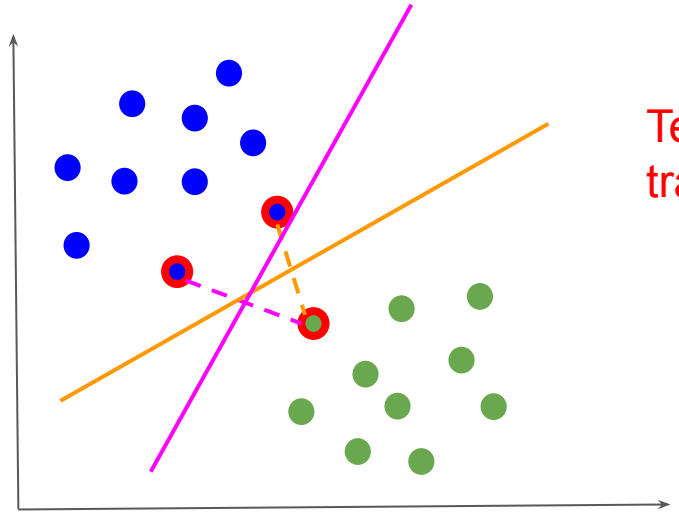


Tendo as retas, é possível traçar sua(s) perpendicular(es)

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- Tendo encontrado os vetores de suporte, é possível traçar uma reta entre eles

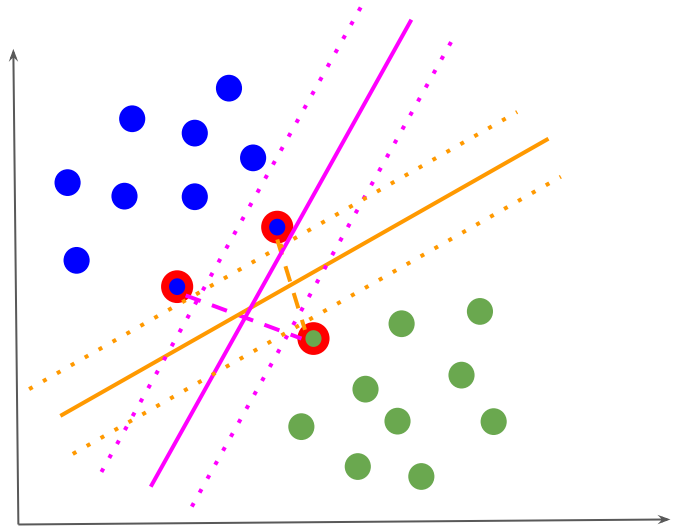


Tendo as retas, é possível traçar sua(s) perpendicular(es)

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

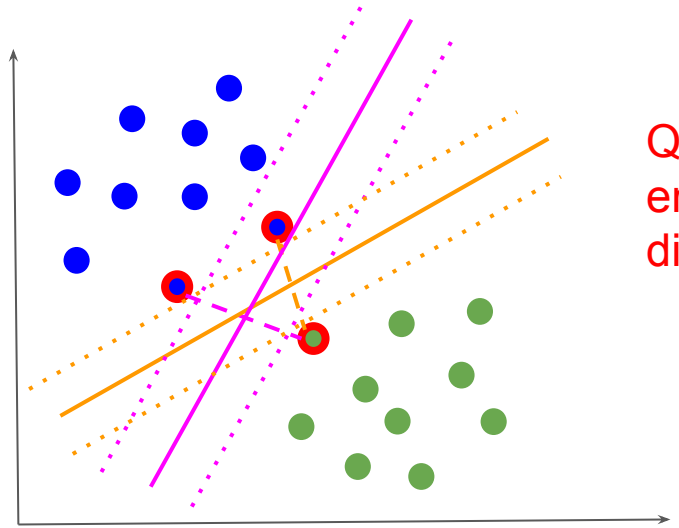
- Também é possível traçar suas "margens"



Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- Também é possível traçar suas "margens"

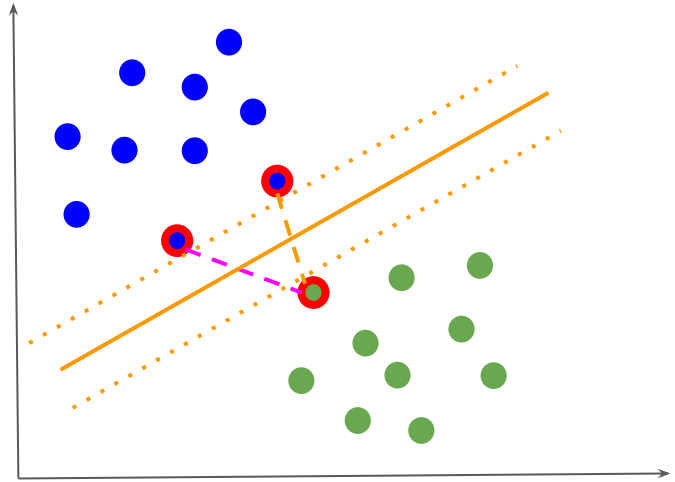


Qual reta oferece a separação entre as classes com maior distância entre as margens ?

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

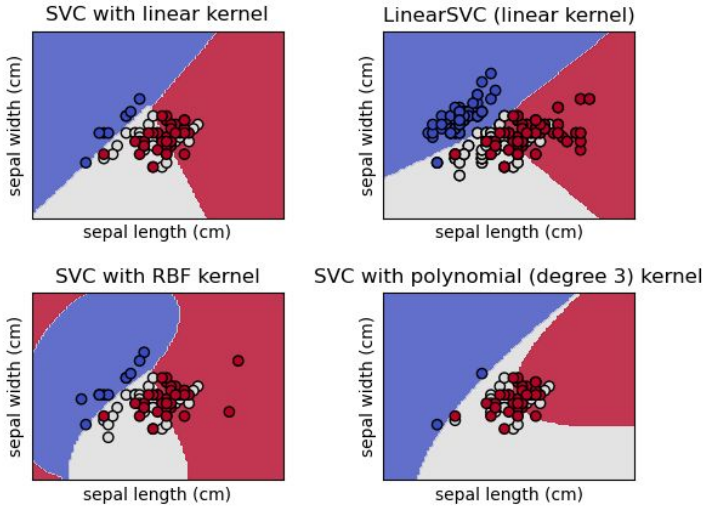
- Esta é a linha que melhor separa nosso exemplo



Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- Existem diferentes possibilidade de separação de classes no algoritmo SVM, são os chamados Kernel (Linear, RBF, Polynomial e Sigmoid)

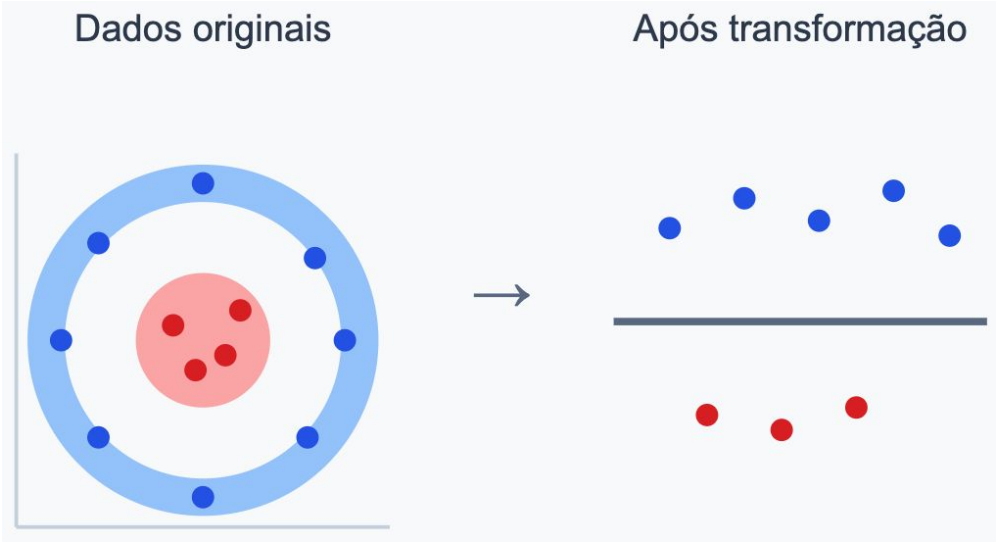


Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*

- A forma mais fácil de entender kernel é pensar que ele é uma maneira de enxergar os dados de outro ângulo

À esquerda, uma reta não consegue separar as classes. O kernel transforma os dados para que, à direita, uma reta consiga separar



- **Kernel = uma transformação matemática que facilita a separação das classes**

Aprendizado de Máquina - Supervisionado

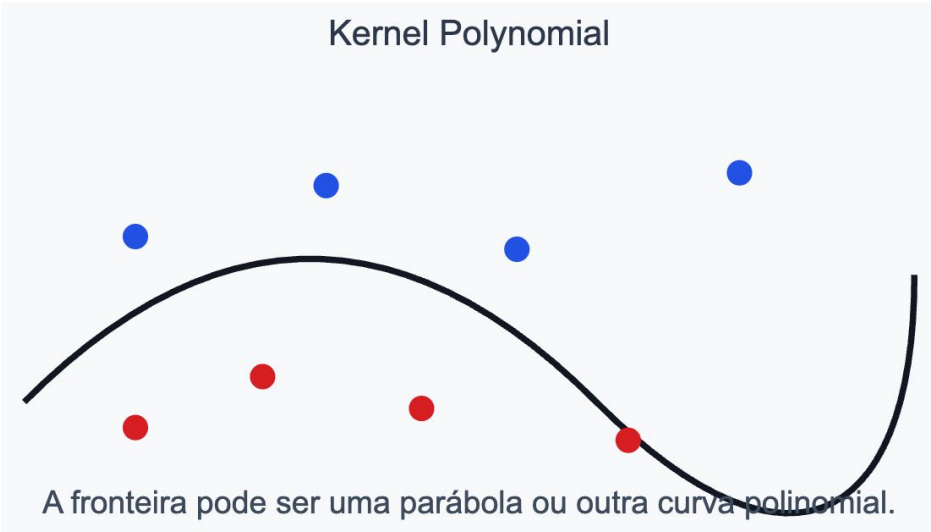
- ➔ SVM - Kernel Linear
  - ◆ Ele não transforma os dados, desenha apenas uma reta (ou plano, em dimensões maiores)



  - ◆ **Use quando: os dados já são naturalmente separados**
    - **Exemplo: altura × peso para distinguir crianças e adultos**

Aprendizado de Máquina - Supervisionado

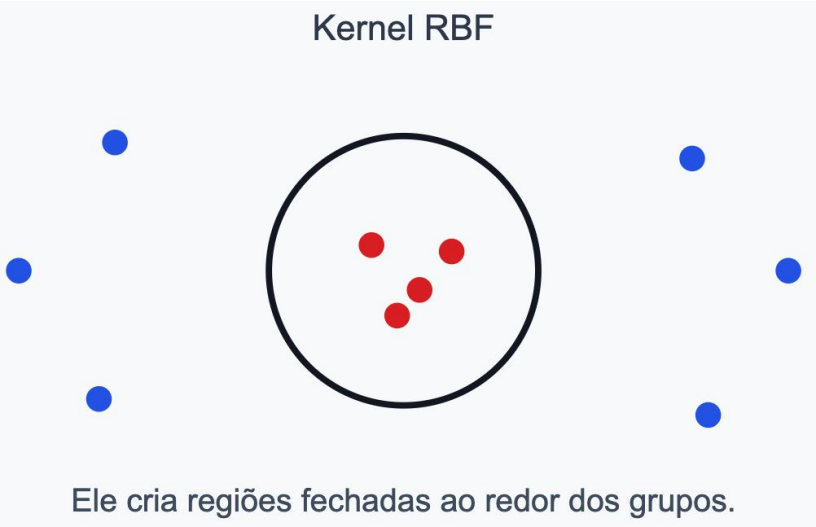
- SVM - Kernel Polynomial
  - Em vez de uma reta, ele pode criar uma parábola, cúbica etc.



  - **Use quando: existe uma relação curvada entre as classes**

Aprendizado de Máquina - Supervisionado

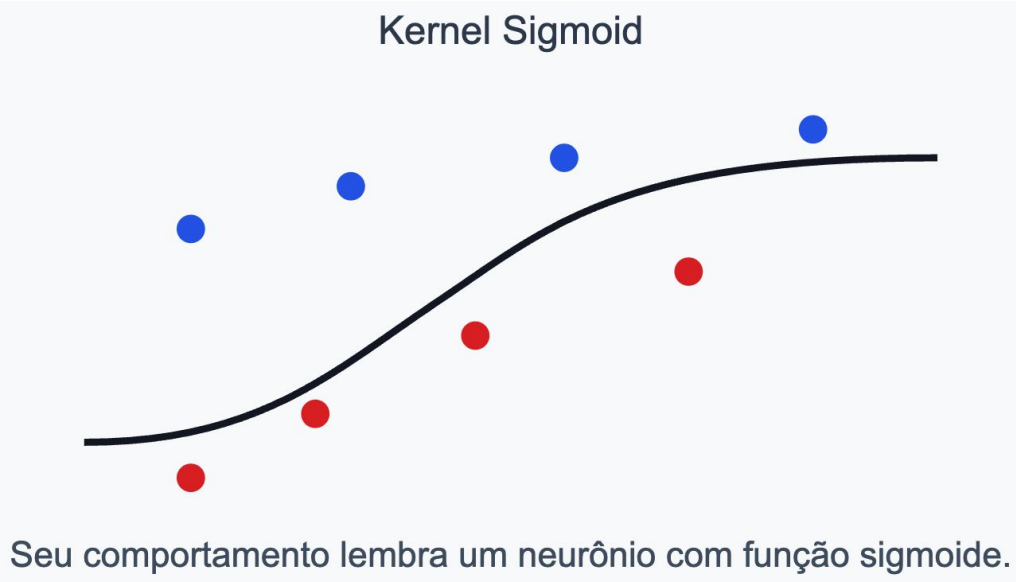
- ➔ SVM - Kernel RBF
  - ◆ Pense nele como desenhando uma bolha ao redor de grupos de pontos



  - ◆ **Use quando: os dados têm formatos irregulares**

Aprendizado de Máquina - Supervisionado

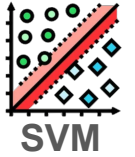
- SVM - Kernel Sigmoid
  - Ele produz uma separação parecida com uma curva em S



  - Ele foi inspirado nas redes neurais antigas

Aprendizado de Máquina - Supervisionado

➔ Maquina de Suporte de Vetores - *Support Vector Machine*



Kernel	Nome	Ideia principal	Uso típico
Linear	Linear	Fronteira reta/plana	Dados aproximadamente separáveis linearmente
Polynomial	Polinomial	Cria fronteiras curvas usando polinômios	Relações não lineares
RBF	Radial Basis Function	Mede a influência dos pontos pela distância	Muito usado em dados não lineares
Sigmoid	Sigmoide	Usa uma função semelhante à de redes neurais	Menos comum

Aprendizado de Máquina - Supervisionado



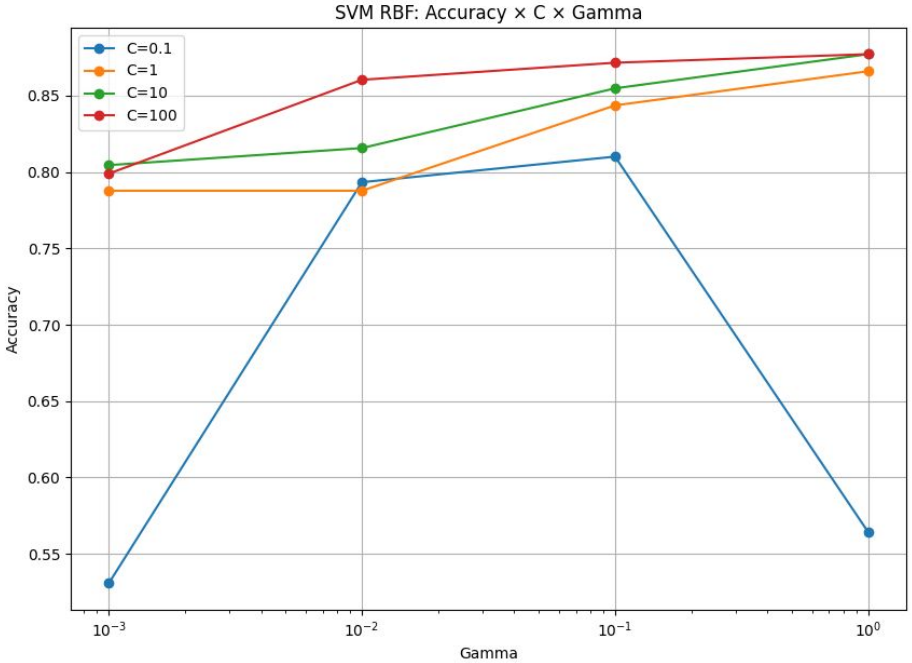


➔ Maquina de Suporte de Vetores - *Support Vector Machine*

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_04.py
```

Aprendizado de Máquina - Supervisionado

➔ SVM - Gamma e C



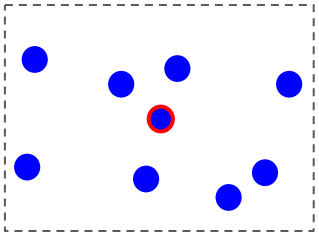
Gamma → imagine que cada ponto tenha uma espécie de "campo de influência"

Quanto um ponto contribui para determinar a semelhança entre os dados

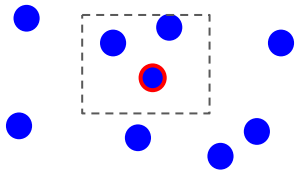
O SVM vai "pensar" que os elementos são da mesma classe

Aprendizado de Máquina - Supervisionado

➔ SVM - Gamma e C



Gamma Pequeno → influência maior, vai "atingir" pontos mais distantes



Gamma Maior → influência menor, vai "atingir" pontos mais próximos apenas

Aprendizado de Máquina - Supervisionado





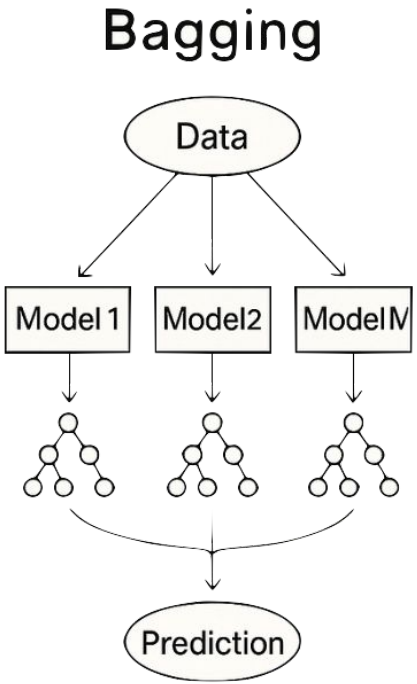


- ➔ Métodos Ensemble
  - ◆ Ensemble significa combinar vários modelos de aprendizado de máquina para tomar uma decisão em conjunto

  - ◆ Por que usar vários modelos?
    - Porque cada modelo pode cometer erros diferentes

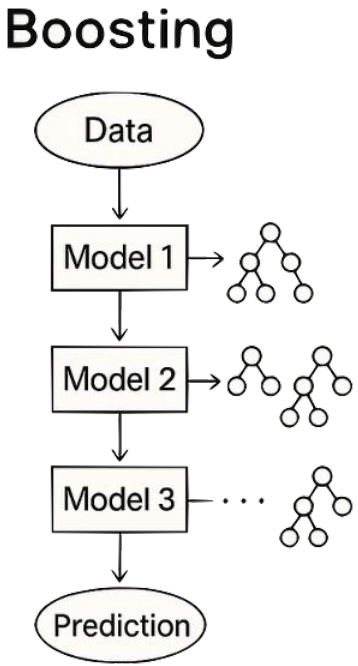
Aprendizado de Máquina - Supervisionado

- Métodos Ensemble - *Bagging*
  - Os modelos trabalham independentemente
  - Exemplo: Random Forest



Aprendizado de Máquina - Supervisionado

- Métodos Ensemble - *Boosting*
  - Os modelos são construídos um depois do outro
  - O próximo modelo tenta melhorar os erros cometidos anteriormente.



Aprendizado de Máquina - Supervisionado

➔ Métodos Ensemble - *Boosting*

- No XGBoost, os modelos combinados são árvores de decisão, mais precisamente árvores geralmente pequenas e regularizadas

- Tecnicamente, o XGBoost não passa simplesmente os erros de uma árvore para outra; ele utiliza o gradiente e a hessiana da função de perda para determinar como a próxima árvore deve melhorar o modelo

- O gradiente diz para a próxima árvore "o que precisa ser corrigido". A Hessiana diz "o quanto essa correção deve ser ajustada considerando a forma da função de erro"

Aprendizado de Máquina - Supervisionado

➔ Métodos Ensemble - *Boosting*

- No XGBoost, os modelos combinados são árvores de decisão, mais precisamente árvores geralmente pequenas e regularizadas

- Tecnicamente, o XGBoost não passa simplesmente os erros de uma árvore para outra; ele utiliza o gradiente e a hessiana da função de perda para determinar **como a próxima árvore deve melhorar o modelo**

- O gradiente diz para a próxima árvore "o que precisa ser corrigido". A Hessiana diz "o quanto essa correção deve ser ajustada considerando a forma da função de erro"

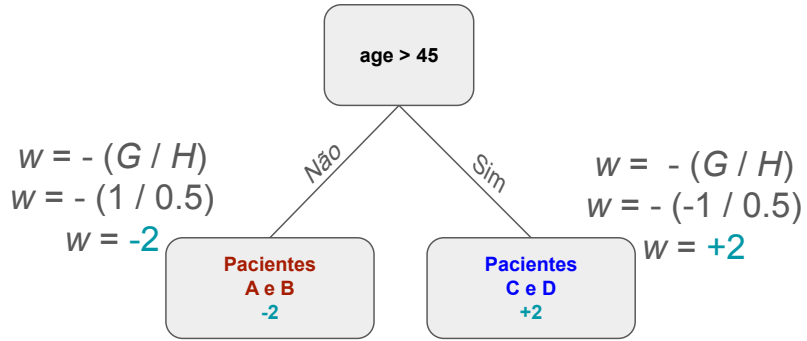
Aprendizado de Máquina - Supervisionado

➔ Calculando o *Gradiente* e *Hessiana*

Paciente	Target (*y*)	Probabilidade inicial do modelo *p*	*Gradiente* *g = p - y*	*Hessiana* *h = p (1 - p)*
A	0	0,5	0,5	0,25
B	0	0,5	0,5	0,25
C	1	0,5	-0,5	0,25
D	1	0,5	-0,5	0,25
...	...	...	...	...

Menor ou igual a 45 anos
Maior que 45 anos

A primeira Árvore ficaria assim:



A soma da Hessiana foi 0,25 + 0,25 = 0,5 para cada "ramo" da árvore

Aprendizado de Máquina - Supervisionado

➔ Calculando o *Gradiente* e *Hessiana*

Paciente	Target (*y*)	Probabilidade inicial do modelo *p*	*Gradiente* *g = p - y*	*Hessiana* *h = p (1 - p)*	*w*	*z*
A	0	0,5	0,5	0,25	-2	0
B	0	0,5	0,5	0,25	-2	0
C	1	0,5	-0,5	0,25	2	0
D	1	0,5	-0,5	0,25	2	0
...	...	...	...	...	...	...

Menor ou igual a 45 anos

Maior que 45 anos

Estado Inicial do Modelo

Contribuição da Árvore Anterior

Paciente com 40 anos:

$Z_{novo} = Z_{anterior} + w_{anterior}$

$Z_{novo} = 0+(-2)$

$Z_{novo} = -2$

Função Logistica:

$p = 1 / (1 + e^{-z})$

$p = 1 / (1 + e^{2})$

p = 0,119

Paciente com 49 anos:

$Z_{novo} = Z_{anterior} + w_{anterior}$

$Z_{novo} = 0+2$

$Z_{novo} = 2$

Função Logistica:

$p = 1 / (1 + e^{-z})$

$p = 1 / (1 + e^{-2})$

p = 0,881

Aprendizado de Máquina - Supervisionado

➔ Calculando o *Gradiente* e *Hessiana*

Paciente	Target (y)	Probabilidade inicial do modelo *p*	*Gradiente* *g = p - y*	*Hessiana* *h = p (1 - p)*	*w*
A	0	0,119	0,119	0,1048	-1,1350
B	0	0,119	0,119	0,1048	-1,1350
C	1	0,881	-0,119	0,1048	1,1350
D	1	0,881	-0,119	0,1048	1,1350
...	...	...	...	...	...

Menor ou igual a 45 anos

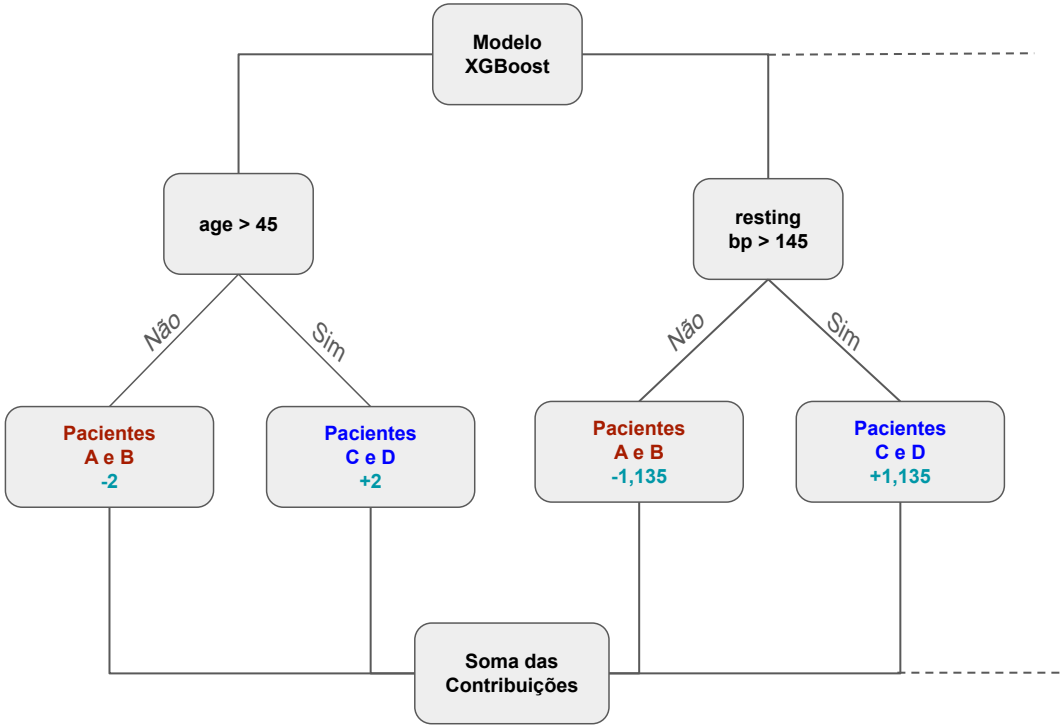
Maior que 45 anos

A soma da Hessiana foi 0,1048 + 0,1048 = 0,2096 para cada "ramo" da árvore

Aprendizado de Máquina - Supervisionado

Paciente	Target (*y*)	*w*
A (140)	0	-1,1350
B (130)	0	-1,1350
C (160)	1	1,1350
D (150)	1	1,1350
...	...	...

$z = 0 \pm 2 \pm 1{,}135$
$z = \pm 3{,}135$



Aprendizado de Máquina - Supervisionado

- *Gradiente (G)*
  - A Inclinação e a Direção do Erro
    - **O que aponta**: Indica a direção e a magnitude da primeira derivada da função de perda (erro) em relação à previsão atual
    - **Na prática**: É uma medida direta do erro de previsão

- *Hessiana (H)*
  - A Curvatura e a Certeza do Modelo
    - **O que aponta**: Indica a curvatura (segunda derivada) da função de perda. Em termos simples, aponta o quão rápido o gradiente está mudando ou quanta informação/certeza aquele dado carrega
    - **Na prática**: Funciona como uma medida de confiança/sensibilidade
    - Hessiana
      - Alta (incerteza) nas previsões
      - Baixa (certeza) nas previsões

Aprendizado de Máquina - Supervisionado



- *Decision Tree*
  - utilizam coeficiente de Gini, Entropia ou Log Loss para definir o ponto de corte para uma nova sub-árvore

- XGBoost
  - calcula o Ganho de Qualidade (Gain) usando os valores de *G* e *H* da esquerda, da direita e do nó pai

Aprendizado de Máquina - Supervisionado

➔ Métodos Ensemble - *Boosting*

```
pip install xgboost

brew install libomp

python -c "from xgboost import XGBClassifier; print('XGBoost funcionando corretamente')"

Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_05.py
```

Aprendizado de Máquina - Supervisionado

- KNN, SVM, Árvores de Decisão, Random Forest, XGBoost vistos e ainda outros são algoritmos discriminativos
  - aprendem a fronteira de separação diretamente dos dados

- LDA, QDA e outros são algoritmos gerativos
  - modelam a distribuição de probabilidade de cada classe usando estatística bayesiana

Aprendizado de Máquina - Supervisionado

- Análise Discriminante Linear (LDA)
  - Ronald Fisher propôs o método original (discriminante linear de Fisher) em 1936 no artigo "The Use of Multiple Measurements in Taxonomic Problems", usando medidas de flores para separar espécies

  - Em 1948, o estatístico C. R. Rao expandiu a teoria matemática para acomodar mais de duas classes simultaneamente, formando a base da LDA moderna

Aprendizado de Máquina - Supervisionado

- *Public Health Dataset* (acessado em 10/08/2026)
  - https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset

age	sex	chest pain type	resting bp s	choleste rol	fasting blood sugar	resting ecg	max heart rate	exercise angina	oldpeak	ST slope	target
40	1	2	140	289	0	0	172	0	0.0	1	0
49	0	3	160	180	0	0	156	0	1.0	2	1
37	1	2	130	283	0	1	98	0	0.0	1	0
48	0	4	138	214	0	0	108	1	1.5	2	1
54	1	3	150	195	0	0	122	0	0.0	1	0
39	1	3	120	339	0	0	170	0	0.0	1	0
58	1	2	136	164	0	1	99	1	2.0	2	1
45	0	2	130	237	0	0	170	0	0.0	1	0
54	1	2	110	208	0	0	142	0	0.0	1	0
37	1	4	140	207	0	0	130	1	1.5	2	1

O LDA quer entender o que separa os pacientes **Saudáveis** (`target = 0`) dos pacientes **Com Doença Cardíaca** (`target = 1`)

Aprendizado de Máquina - Supervisionado

Variável / Exame	Média no Grupo Saudável (target = 0)	Média no Grupo Doente (target = 1)	Diferença Percebida pelo LDA
age (Idade)	**44,8 anos**	**48,0 anos**	Pequena
cholesterol (Colesterol)	**258,7 mg/dL**	**190,2 mg/dL**	Moderada
max heart rate (Freq. Cardíaca Máx.)	**145,7 bpm**	**123,2 bpm**	Moderada
oldpeak (Infradesnivelamento ST)	**0**	**1,5**	**Enorme!**
exercise angina (Angina por Exercício)	**0,00 (0%)**	**0,75 (75%)**	**Enorme!**
ST slope (Inclinação ST)	**1**	**2**	**Enorme!**

Aprendizado de Máquina - Supervisionado

- ➔ Descobrindo as Variáveis Discriminantes
  - ◆ Variáveis com pouca importância
    - A Idade (age) é muito próxima nos dois grupos (~45 vs ~48 anos). O LDA atribui um peso quase nulo a ela

  - ◆ Variáveis com Alta Importância (Fortes Discriminantes)
    - oldpeak: No grupo saudável a média é exatamente 0,0. No grupo doente, salta para 1,5
    - exercise angina: NENHUM saudável tem angina induzida por exercício (0%), enquanto 75% dos doentes apresentam esse sintoma (valor 1)
    - ST slope: É sempre 1 no grupo saudável e 2 no grupo doente

Aprendizado de Máquina - Supervisionado

➔ O LDA multiplica cada variável por um peso (*w*) proporcional à sua capacidade de separar os grupos:

Escore LDA = (w_1 x *oldpeak*) + (w_2 x *exercice_angina*) + (w_3 x *ST_slope*) - (w_4 x *max_heart_rate*) + … + Constante

- *oldpeak*, *exercise_angina* e *ST_slope* ganham pesos positivos elevados
  - a presença deles empurra o Escore para cima

- *max_heart_rate* ganha um peso negativo
  - frequência cardíaca máxima alta empurra o Escore para baixo, indicando saúde

Aprendizado de Máquina - Supervisionado

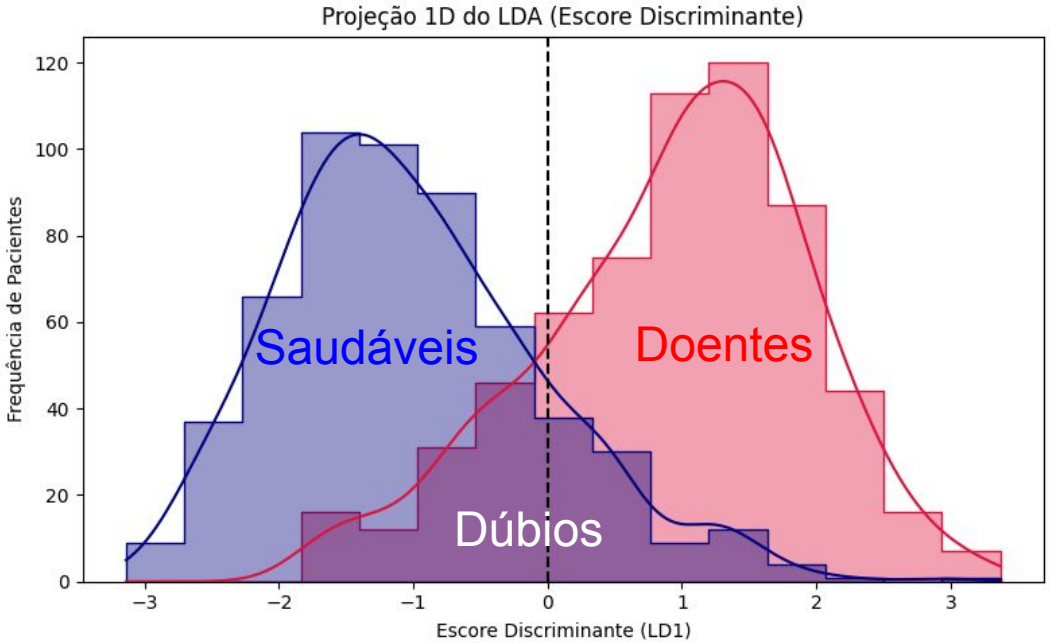
➔ Método Análise Discriminante Linear (LDA)

```
pip install seaborn

Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_06.py
```

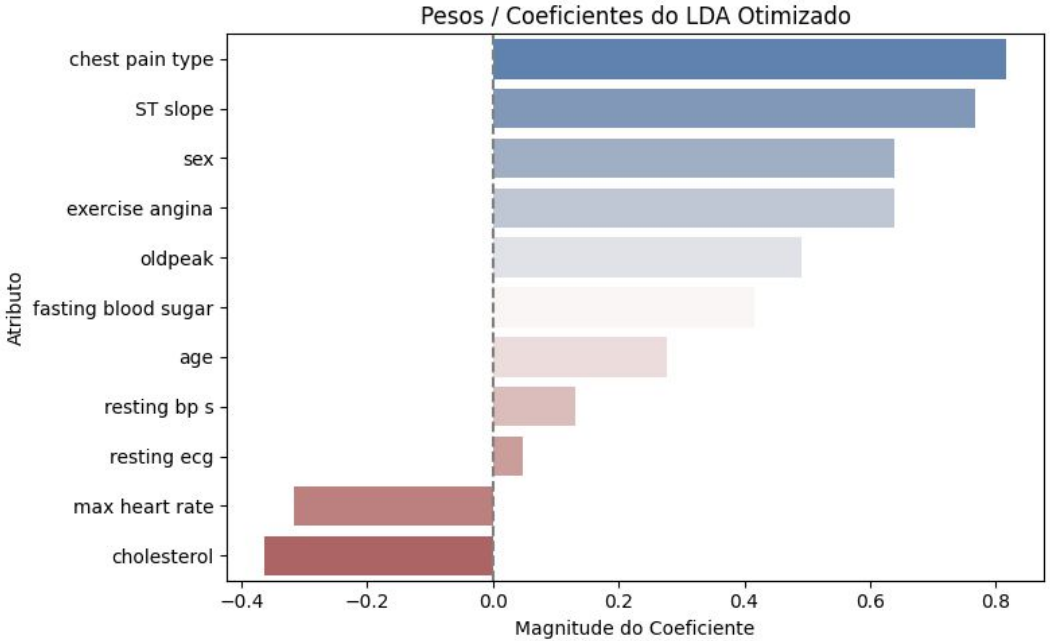
Aprendizado de Máquina - Supervisionado

➔ Método Análise Discriminante Linear (LDA)



Aprendizado de Máquina - Supervisionado

➔ Método Análise Discriminante Linear (LDA)



Aprendizado de Máquina - Supervisionado

- Avaliadores de Características
  - Ao aplicarmos técnicas de Aprendizado de Máquinas, é importante conhecer as características a serem processadas
  - Existem diversas opções de algoritmos para tal

- *Permutation Feature Importance*
  - É considerada a melhor técnica universal para ranquear variáveis sem se importar com a escolha do modelo final

Aprendizado de Máquina - Supervisionado

- ➔ *Permutation Feature Importance*
  - Treina qualquer modelo e, no conjunto de validação/teste, o algoritmo embaralha aleatoriamente uma coluna por vez. A queda na performance (ex: queda na Acurácia ou AUC) indica a importância real daquela variável

  - Por que é considerada uma das melhores opções:
    - Funciona para qualquer modelo (LDA, SVM, KNN, Random Forest, XGBoost)
    - Não favorece colunas contínuas com muitas categorias únicas (um defeito clássico do *Feature Importance* nativo de árvores)
    - Captura interações complexas e não-lineares que seletores estatísticos simples não enxergam

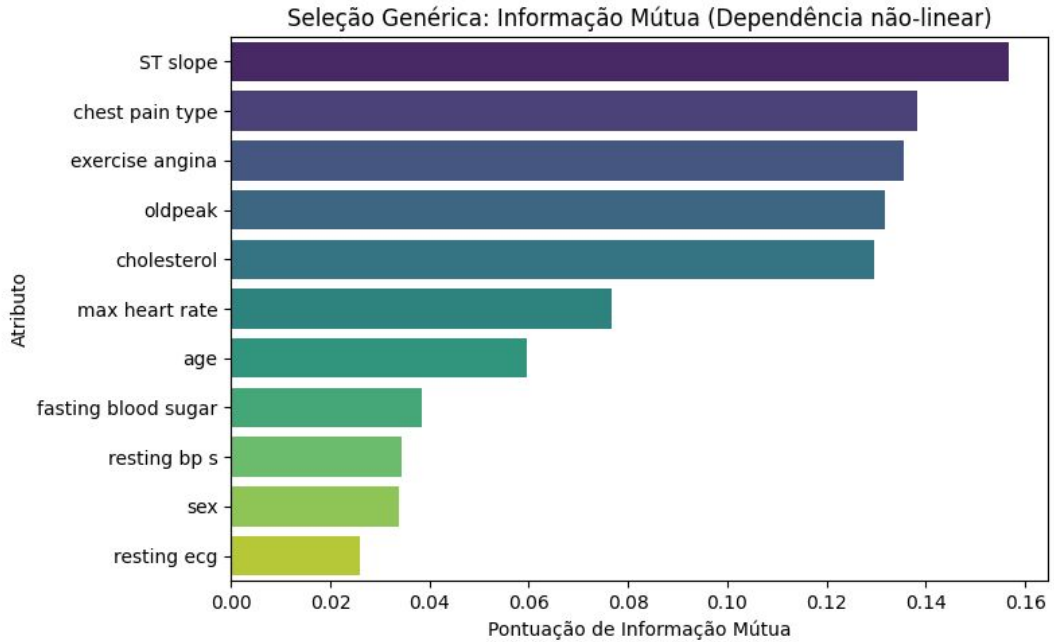
Aprendizado de Máquina - Supervisionado

➔ *Permutation Feature Importance*

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/supervisionado_07.py
```

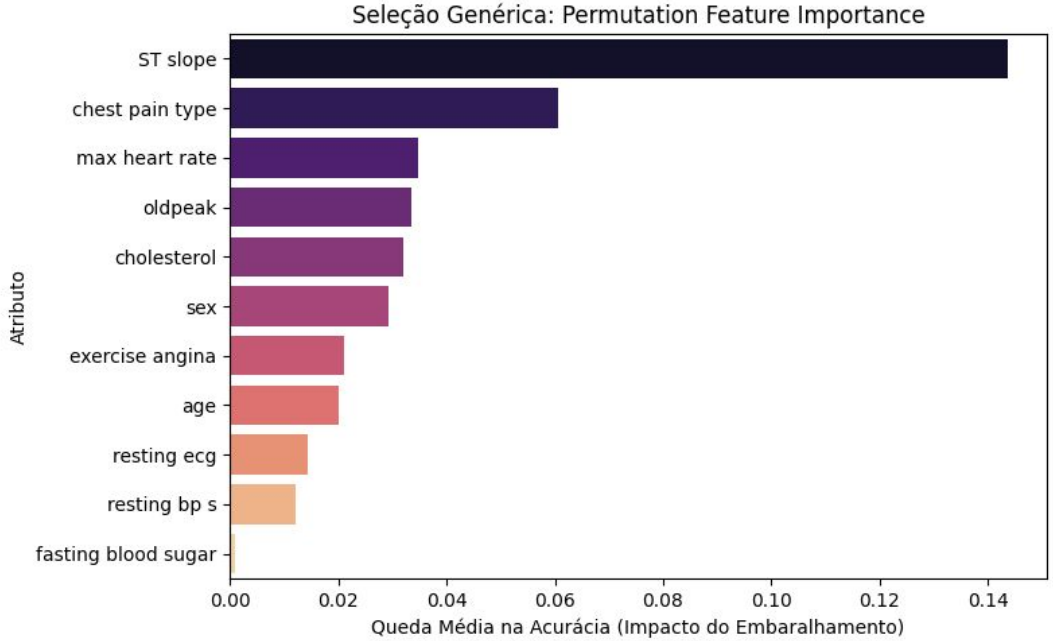
Aprendizado de Máquina - Supervisionado

➔ *Permutation Feature Importance*



Aprendizado de Máquina - Supervisionado

➔ *Permutation Feature Importance*



Aprendizado de Máquina - Supervisionado

➔ *Permutation Feature Importance*

Critério	Gráfico 1 (Informação Mútua)	Gráfico 2 (Permutation Importance)
Depende de Modelo?	❌ Não (Avalia os dados puros)	✅ Sim (Avalia a performance do RandomForest)
O que indica um valor alto?	A variável isolada contém muita informação sobre a classe.	Embaralhar essa variável destrói a acurácia do modelo.
Captura interações?	❌ Não (Olha atributo por atributo)	✅ Sim (O modelo usa variáveis combinadas)
Uso Principal	Pré-filtragem rápida antes de qualquer modelagem.	Decisão final sobre quais variáveis manter no pipeline.

Aprendizado de Máquina - Supervisionado

➔ Existem outros Avaliadores de Características

Método	Tipo	Vantagens	Quando Usar
Permutation Importance	Model-Agnostic	Mede a perda real de acurácia de qualquer modelo ao remover a informação.	**Melhor escolha geral após treinar qualquer modelo inicial.**
SHAP Values	Model-Agnostic	Mede a contribuição exata e a direção de cada variável para cada amostra.	Para explicar o modelo e selecionar atributos em datasets complexos.
Mutual Information	Filter (Estatístico)	Não precisa de nenhum modelo de Machine Learning, calcula direto dos dados.	Pré-filtragem rápida antes de rodar qualquer pipeline.

Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA

