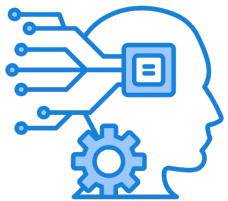
Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA



Aprendizado de Máquina - Não Supervisionado

➔ No aprendizado não supervisionado, fornecemos os dados ao algoritmo sem informar qual é a resposta correta para cada exemplo

Aprendizado Supervisionado
Qual o padrão que sugere o Diagnóstico ?

Idade	Pressão	Colesterol	Diagnóstico
25	120	180	Não
62	160	250	Sim
45	145	230	Sim

Aprendizado NÃO Supervisionado
Existe um padrão que "separa" as amostras ?

Idade	Pressão	Colesterol
25	120	180
62	160	250
45	145	230

Aprendizado de Máquina - Não Supervisionado

- Principais abordagens do aprendizado NÃO Supervisionado
  - Agrupamento (*Clustering*)
    - A mair conhecida: encontrar grupos de elementos semelhantes dentro dos dados
  - Redução de dimensionalidade
    - procura representar os dados usando menos dimensões, preservando, tanto quanto possível, as informações importantes
  - Detecção de anomalias
    - Procura identificar elementos que apresentam um comportamento muito diferente do padrão dos demais dados. Exemplo: Detecção de Fraudes

Aprendizado de Máquina - Não Supervisionado

- Principais abordagens do aprendizado NÃO Supervisionado
  - Regras de associação
    - Procura descobrir relações ou padrões de ocorrência entre diferentes elementos dos dados. Exemplo: Indicação de Clientes
  - Modelagem de distribuição/densidade
    - Procura entender e representar como os dados estão distribuídos, identificando regiões onde os dados estão mais ou menos concentrados. Exemplo: identificar clientes por idade ou renda
  - Métodos de representação e aprendizado de características
    - Procura aprender automaticamente as características ou representações mais importantes dos dados, sem que seja necessário defini-las manualmente. Exemplo: em imagens, aprender automaticamente características como bordas, formas e padrões que representam os objetos

Aprendizado de Máquina - Não Supervisionado

➔ O Algoritmo K-Means

- Hugo Steinhaus (1957) introduziu o conceito inicial na Polônia

- Stuart Lloyd desenvolveu a versão clássica em 1957 (no Bell Labs) como uma técnica para modulação por código de pulso (processamento de sinais), embora seu trabalho só tenha sido publicado oficialmente em 1982 (Lloyd's Algorithm)

- O Termo "K-Means": Foi proposto por James MacQueen em 1967, em seu famoso artigo onde formalizou o método para a comunidade científica e estatística

- Propósito Original: Encontrar partições ótimas em conjuntos de dados para redução de dimensionalidade, compressão de dados e quantização vetorial

Aprendizado de Máquina - Não Supervisionado

- ➔ O Algoritmo K-Means
  - ◆ O objetivo principal do K-Means é particionar um conjunto de *n* observações em *k* clusters (grupos), de modo que cada observação pertença ao cluster com a média (centroide) mais próxima

  - ◆ Objetivos:
    - Maximizar a Coesão Interna: Pontos dentro do mesmo cluster devem ser o mais parecidos possível entre si
    - Maximizar a Separação Externa: Clusters diferentes devem ser o mais distintos possível entre si
    - Aplicações Clássicas: Segmentação de clientes, compressão de imagens, detecção de anomalias, pré-processamento para modelos supervisionados e recomendação de produtos

Aprendizado de Máquina - Não Supervisionado

1. Definir o valor de K (ex: k = 3)
2. Inicializar K centroides aleatoriamente
3. [Passo de Atribuição / Expectation]
   3.1 Calcular a distância de cada ponto a todos os centroides
   3.2 Atribuir o ponto ao centroide mais próximo (ex: Distância Euclidiana)
4. [Passo de Atualização / Maximization]
   4.1 Recalcular o centroide de cada cluster tirando a média dos pontos atribuídos a ele
5. [Critério de Parada]

   Os centroides mudaram de posição?

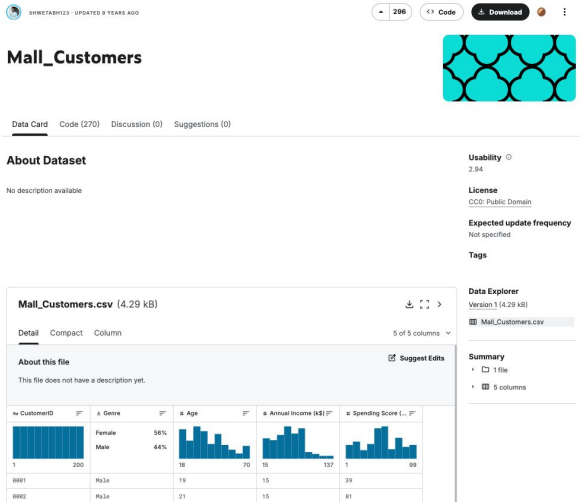
   Sim → Retorna ao Passo 3

   Não → [Fim / Convergência Alcançada]

Classificação com dados do Kaggle

- *Mall Customer* (acessado em 10/08/2026)
  - https://www.kaggle.com/datasets/shwetabh123/mall-customers

```
Caminho e nome do arquivo
    /Users/ronaldomartinsdacosta/am-env/python_scripts/Nsupervisionado_01.csv
```



Classificação com dados do Kaggle

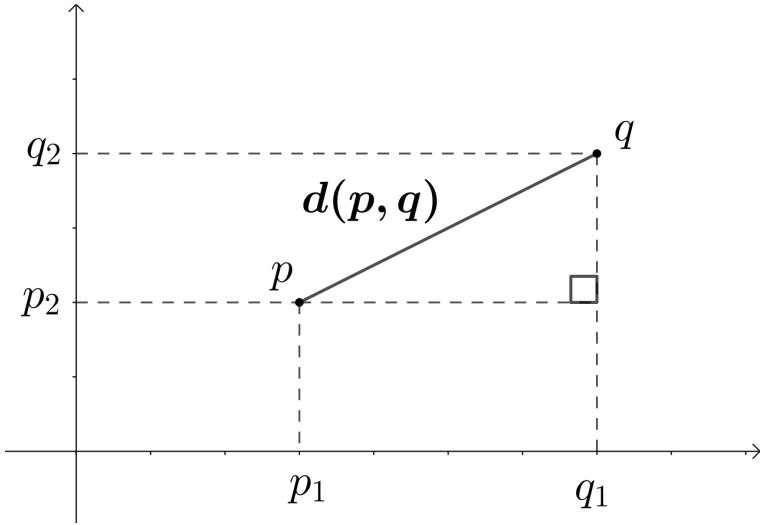
➔ *K-Means*

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/Nsupervisionado_01.py
```

Aprendizado de Máquina - Não Supervisionado

➔ Distância (3.1 e 3.2)

$$D_e(p,q) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$



Existem outras formas de calcular a distância

Aprendizado de Máquina - Não Supervisionado

➔ A Necessidade Crítica da Normalização / Padronização

- O K-Means baseia-se em distâncias euclidianas

- Se uma variável estiver em milhares (ex: Renda = R$ 50.000) e outra em dezenas (ex: Idade = 30), a variável de maior escala dominará o cálculo da distância

Aprendizado de Máquina - Não Supervisionado

➔ Métricas de Qualidade e Escolha de *k*

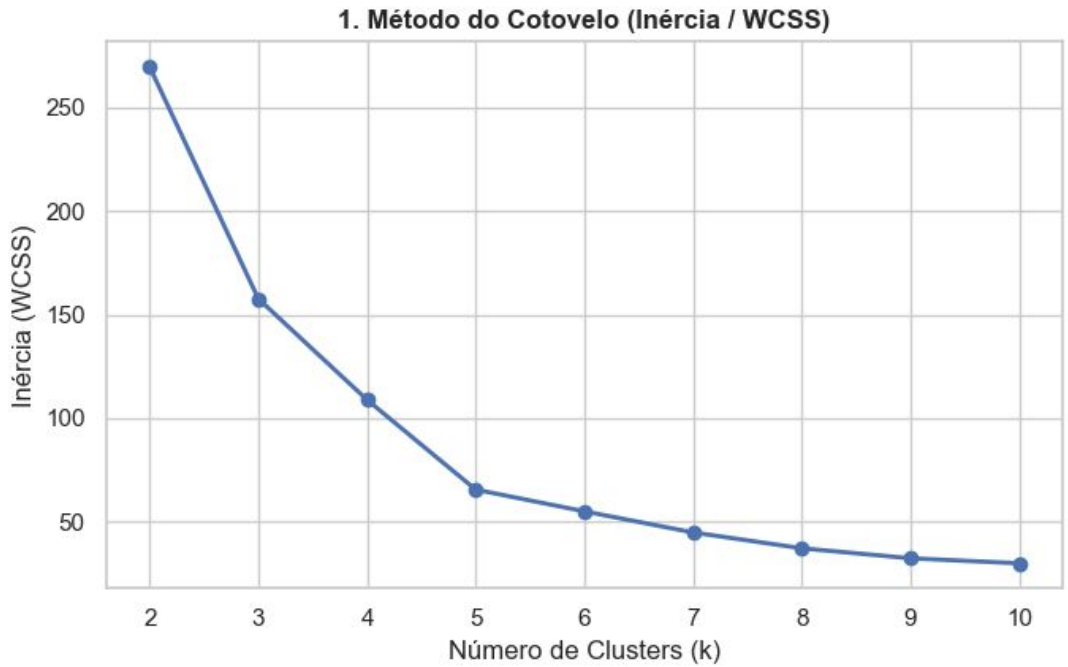
- Inércia / WCSS (*Within-Cluster Sum of Squares*) - Cotovelo

  - Mede o quão compactos estão os clusters
  - Utilizada no Método do Cotovelo (*Elbow Method*)
  - Objetivo: Quanto menor, melhor (mas decresce monotonicamente com o aumento de *k*, exigindo a busca pelo ponto de inflexão)

- A Inércia (WCSS) mede a "distância física" média entre os clientes e o centroide do seu grupo, como calcular o quanto os clientes de alta renda e alto gasto estão próximos do perfil típico (centroide) daquela loja, sendo que quanto menor esse valor, mais parecido cada cliente é com o seu grupo

Aprendizado de Máquina - Não Supervisionado

- ➔ Métricas de Qualidade e Escolha de *k*
  - ◆ Inércia / WCSS (*Within-Cluster Sum of Squares*) - Cotovelo



Aprendizado de Máquina - Não Supervisionado

➔ Métricas de Qualidade e Escolha de *k*

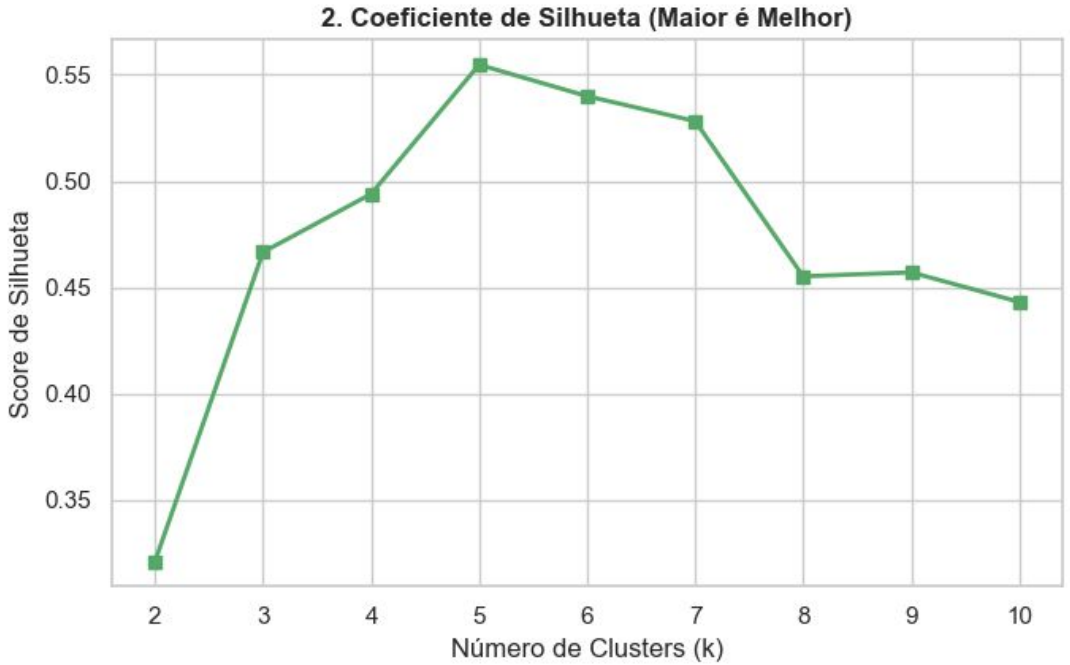
- Coeficiente de Silhueta (*Silhouette Score*)

  - Compara a distância média de um ponto para os membros do seu próprio cluster (*a*) com a distância média para o cluster vizinho mais próximo (*b*)
  - Intervalo: -1 a +1. Quanto mais próximo de +1, melhor a definição do agrupamento

- Mede o "grau de certeza" de um cliente pertencer ao grupo certo, um cliente de baixa renda e alto gasto terá um score próximo de +1 se estiver colado no grupo de clientes impulsivos e bem longe do grupo de clientes moderados

Aprendizado de Máquina - Não Supervisionado

- ➔ Métricas de Qualidade e Escolha de *k*
  - ◆ Coeficiente de Silhueta (*Silhouette Score*)



Aprendizado de Máquina - Não Supervisionado

➔ Métricas de Qualidade e Escolha de *k*

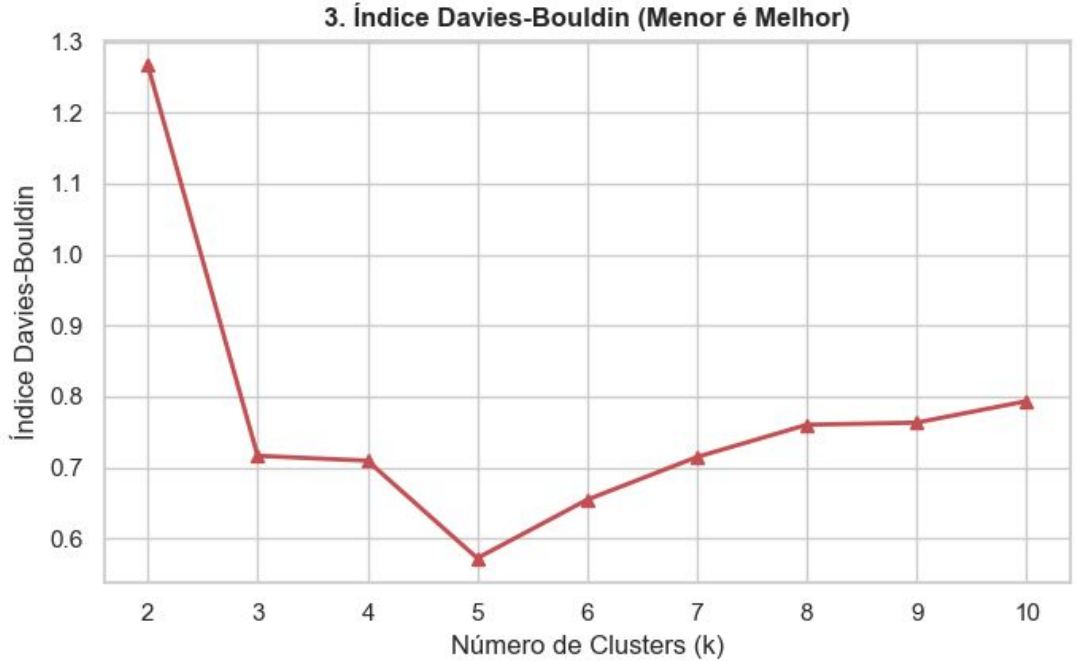
- Índice Davies-Bouldin

  - Calcula a razão de similaridade entre cada cluster e o seu cluster mais próximo
  - Objetivo: Quanto menor, melhor (menor sobreposição entre grupos)

- Mede a "confusão" ou sobreposição entre os perfis de clientes, ele avalia a razão entre o espalhamento dos clientes dentro do grupo de alto gasto e a distância desse grupo para o de baixo gasto, onde um valor próximo de zero garante que os perfis estão bem separados e que um cliente "moderado" jamais será confundido com um "gastador".

Aprendizado de Máquina - Não Supervisionado

- ➔ Métricas de Qualidade e Escolha de *k*
  - ◆ Índice Davies-Bouldin



Aprendizado de Máquina - Não Supervisionado

➔ Métricas de Qualidade e Escolha de *k*

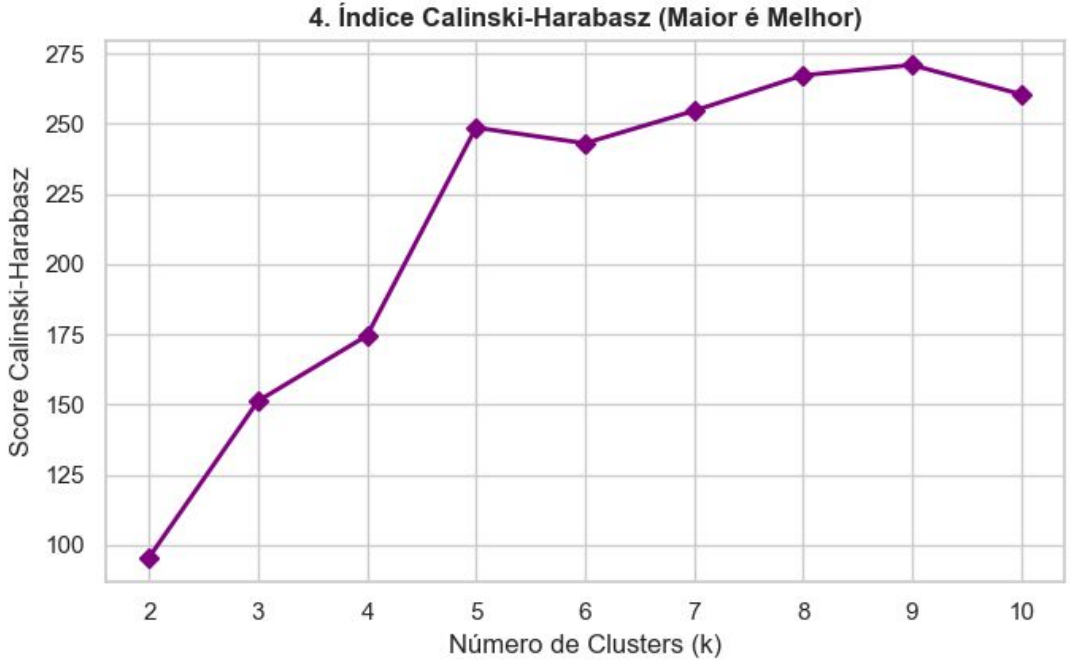
- Índice Calinski-Harabasz (Critério de Razão de Variância)

  - Razão entre a dispersão inter-cluster (entre grupos) e a dispersão intra-cluster (dentro dos grupos)
  - Objetivo: Quanto maior, melhor definido é o agrupamento

- Mede a "força de separação" do agrupamento, ele compara o quão distantes os 5 perfis de clientes estão entre si em relação ao quão juntos os clientes estão dentro de cada perfil, onde um valor alto prova que os grupos de altos gastadores e baixos gastadores formam "ilhas" bem distintas e compactas, em vez de uma nuvem bagunçada de clientes

Aprendizado de Máquina - Não Supervisionado

- ➔ Métricas de Qualidade e Escolha de *k*
  - ◆ Índice Calinski-Harabasz (Critério de Razão de Variância)



Aprendizado de Máquina - Não Supervisionado

➔ O Problema da Inicialização e o K-Means++

- A inicialização aleatória dos centroides pode fazer o algoritmo prender em mínimos locais

- K-Means++ escolhe os centroides iniciais mais distantes uns dos outros proporcionalmente ao quadrado da distância, garantindo uma convergência mais rápida e estável

Aprendizado de Máquina - Não Supervisionado

➔ Limitações do K-Means

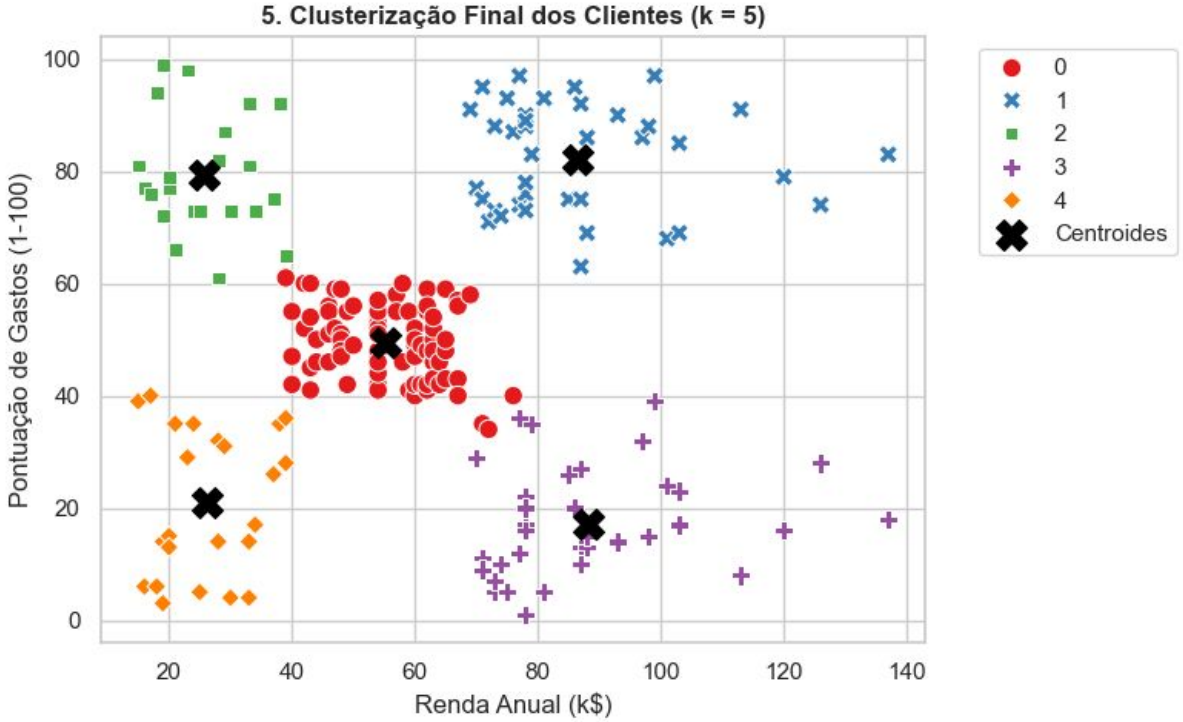
- Geometria dos Clusters:
  - O K-Means assume que os clusters são esféricos/convexos e de tamanhos similares. Ele falha em identificar formas complexas (como círculos concêntricos ou formatos em "C" / feijão).

- Sensibilidade a *Outliers*:
  - Como utiliza a média para recalcular os centróides, pontos discrepantes movem drasticamente o centro do grupo

- Variáveis Categóricas:
  - O K-Means tradicional não funciona diretamente com dados categóricos

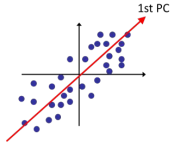
Aprendizado de Máquina - Não Supervisionado

➔ K-Means



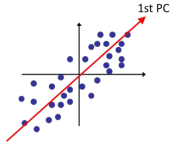
Aprendizado de Máquina - Não Supervisionado

➔ Redução de Dimensionalidade



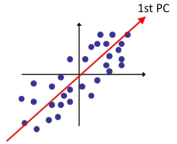
- Cada coluna (*feature*) é uma "dimensão". Para uma tabela com 100 colunas, trabalhamos num espaço de 100 dimensões. A redução de dimensionalidade resume essas 100 colunas "compactas", sem perder os padrões principais que explicam os dados

Aprendizado de Máquina - Não Supervisionado



- ➔ Redução de Dimensionalidade
  - ◆ Exemplo de aplicação
    - Reconhecimento Facial
      - Uma foto de 100 x 100 pixels tem 10.000 dimensões (uma por pixel). Reduzindo para 50 componentes principais, o modelo ignora ruídos e foca apenas nas linhas marcantes do rosto (distância entre olhos, formato do queixo), permitindo comparar rostos rapidamente
    - Compressão de Imagens e Processamento de Áudio
      - Reduzir o tamanho de arquivos eliminando frequências ou detalhes visuais imperceptíveis ao olho/ouvido humano, mantendo a qualidade percebida
    - Sistemas de Recomendações
      - Em vez de analisar o histórico de um usuário contra 50.000 produtos, o algoritmo reduz para 5 ou 10 "perfis" (ex: gostos e preferências)

Aprendizado de Máquina - Não Supervisionado



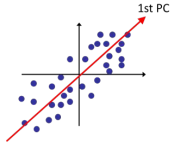
➔ Redução de Dimensionalidade - PCA

- Análise de Componentes Principais - *Principal Component Analysis* (PCA)
  - Técnica de redução de dimensionalidade.

- Dados complexos, com dezenas ou até centenas de colunas (dimensões) deixam os cálculos pesados, geram ruído e torna impossível para nós humanos visualizarmos os dados num gráfico

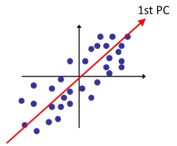
- O PCA funciona como um "compressor de arquivos": ele pega todas as colunas originais e as resume em um número muito menor de "super colunas" (chamadas de Componentes Principais), tentando jogar fora o mínimo possível de informação útil

Aprendizado de Máquina - Não Supervisionado



- ➔ Redução de Dimensionalidade - PCA
  - ◆ Análise de Componentes Principais - *Principal Component Analysis* (PCA)
    - Criador: Famoso matemático e estatístico britânico Karl Pearson
    - Em 1901
    - Evolução: Mais tarde, na década de 1930, o estatístico americano Harold Hotelling desenvolveu e expandiu o método de forma independente, dando a ele a estrutura matricial utilizada hoje no Python e R

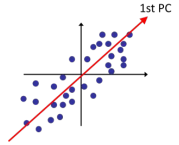
Aprendizado de Máquina - Não Supervisionado



- Redução de Dimensionalidade - PCA
  - Análise de Componentes Principais - *Principal Component Analysis* (PCA)

    - Ele calcula a variação dos seus dados (chamada de variância)
    - Ele encontra as "melhores representações" (eixos) que capturam a maior dispersão dos dados
    - O Componente Principal 1 (PC1) é a linha que pega a maior quantidade de informação/variação dos dados
    - O Componente Principal 2 (PC2) pega a segunda maior quantidade de variação, e assim por diante

Aprendizado de Máquina - Não Supervisionado

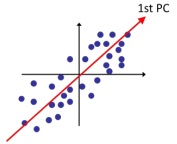


➔ Redução de Dimensionalidade - PCA

- ◆ Análise de Componentes Principais - *Principal Component Analysis* (PCA)

Vantagem	Descrição
Ganhos de Desempenho	Treinar um modelo com 10 ou 15 componentes é absurdamente mais rápido do que treinar com 100 colunas originais.
Visualização de Dados	Permite projetar um conjunto de dados complexo de 50 dimensões em um gráfico simples de 2D ou 3D para identificar agrupamentos (clusters) ou outliers.
Eliminação de Redundância	Resolve o problema da multicolinearidade (quando várias colunas dizem quase a mesma coisa, como "peso em kg" e "peso em libras").
Redução de Ruído	Ao descartar as últimas componentes (que carregam pouca variância), o PCA frequentemente elimina ruídos e pequenas imperfeições da coleta de dados.

Aprendizado de Máquina - Não Supervisionado

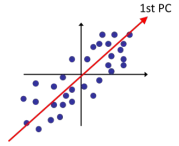


- ➔ Redução de Dimensionalidade - PCA
  - ◆ Análise de Componentes Principais - *Principal Component Analysis* (PCA)

- Perda de Interpretabilidade
  - Uma coluna original chamada Idade é fácil de entender.

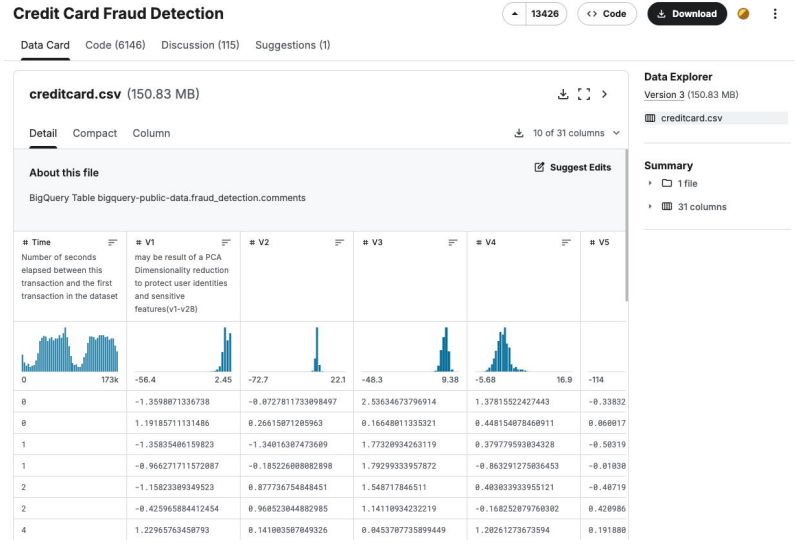
  - A nova coluna PC1 é uma mistura matemática de Idade, Renda, Tempo de Cadastro, etc.
    - ◆ Ganha velocidade no modelo, mas perde a capacidade de explicar o significado exato daquela coluna para uma equipe de negócios

Classificação com dados do Kaggle



- *Credit Card Fraud Detection* (acessado em 10/08/2026)
  - https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

```
Caminho e nome do arquivo
    /Users/ronaldomartinsdacosta/am-env/python_scripts/Nsupervisionado_02.csv
```



Credit Card Fraud Detection

13426 | Code | Download

Data Card | Code (6146) | Discussion (115) | Suggestions (1)

creditcard.csv (150.83 MB)

Detail | Compact | Column | 10 of 31 columns

About this file — Suggest Edits

BigQuery Table bigquery-public-data.fraud_detection.comments

# Time	# V1	# V2	# V3	# V4	# V5
Number of seconds elapsed between this transaction and the first transaction in the dataset	may be result of a PCA Dimensionality reduction to protect user identities and sensitive features(v1-v28)				
0 … 173k	-56.4 … 2.45	-72.7 … 22.1	-48.3 … 9.38	-5.68 … 16.9	-114 …
0	-1.359807133673 8	-0.072781173309 8497	2.536346737969 14	1.378155224274 43	-0.33832
0	1.191857111314 86	0.266150712059 63	0.166480113353 21	0.448154078460 911	0.060017
1	-1.358354061598 23	-1.340163074736 09	1.773209342631 19	0.379779593034 328	-0.50319
1	-0.966271711572 087	-0.185226088088 2898	1.792993339578 72	-0.863291275036 453	-0.01030
2	-1.158233093495 23	0.877736754848 451	1.548717846511	0.403039339551 21	-0.40719
2	-0.425965884124 54	0.960523044882 985	1.141109342322 19	-0.168252079760 302	0.420986
4	1.229657634587 93	0.141083587849 326	0.045370773589 9449	1.202612736735 94	0.191880

Data Explorer

Version 3 (150.83 MB)

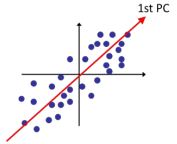
creditcard.csv

Summary

1 file

31 columns

Classificação com dados do Kaggle

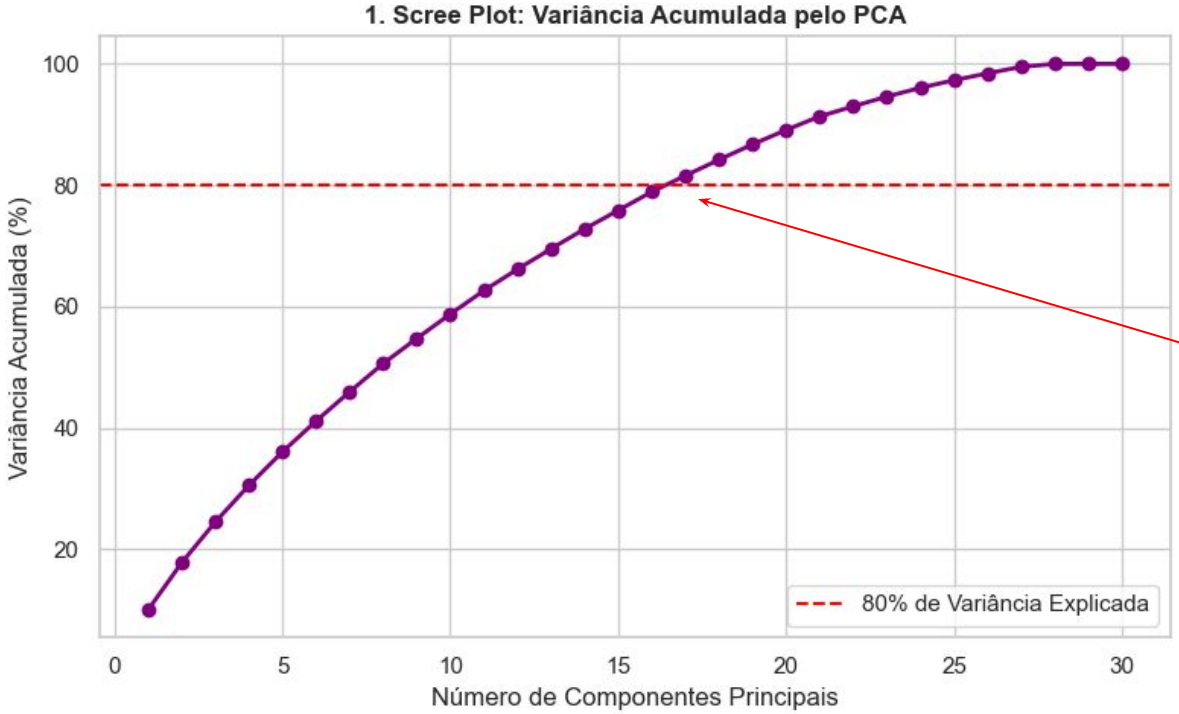


➔ *PCA*

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/Nsupervisionado_02.py
```

Aprendizado de Máquina - Não Supervisionado

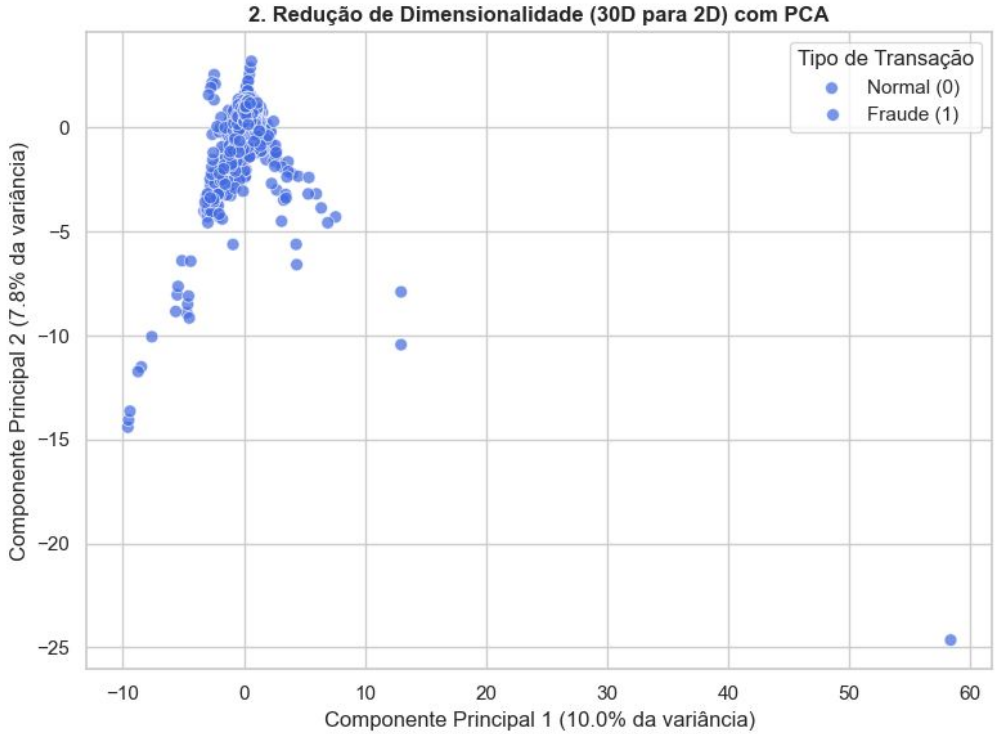
➔ Redução de Dimensionalidade



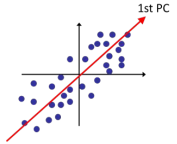
Com 16 características criadas pelo PCA 80% dos dados são "explicados/representado"

Aprendizado de Máquina - Não Supervisionado

➔ Redução de Dimensionalidade



Aprendizado de Máquina - Não Supervisionado



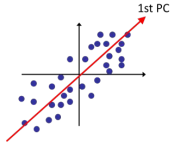
➔ Redução de Dimensionalidade - LDA

- Análise Discriminante Linear - *Linear Discriminant Analysis* (LDA)
  - Método estatístico e de aprendizado de máquina supervisionado usado principalmente para redução de dimensionalidade e classificação

- Enquanto técnicas como o PCA buscam apenas encontrar as direções de maior variação nos dados ignorando, o LDA olha ativamente para as etiquetas/classes dos dados. O objetivo do LDA é encontrar o melhor subespaço que separe o máximo possível as diferentes classes

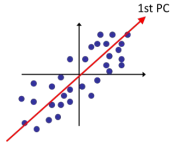
- Imagine que você tem um gráfico 2D com pontos de duas cores, uma cor para cada classe. Se projetarmos esses pontos em uma única linha reta, o LDA tenta encontrar o ângulo dessa reta no qual os dois grupos fiquem o mais distante possível um do outro

Aprendizado de Máquina - Não Supervisionado



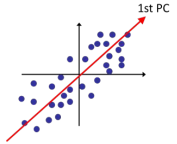
- Redução de Dimensionalidade - LDA
  - O PCA realiza uma transformação sem olhar o rótulo que classifica os dados (Fraude ou Normal), desta forma os dados ficam agrupados sem distinção de acordo com a transformação
  - O LDA busca aprender a separar os dados levando em consideração a característica target

Aprendizado de Máquina - Não Supervisionado



- ➔ Redução de Dimensionalidade - LDA
  - ◆ Primeiro passo:
    - Afastar os grupos ao máximo (Distância entre Médias)
      - Ele ajusta os pesos de cada variável de forma que a média da nota dos clientes normais fique o mais longe possível da média da nota das fraudes
  - ◆ Segundo passo:
    - Manter cada grupo "compacto" (Baixa Variância Interna)
      - Não adianta só afastar as médias se a nota das fraudes variar muito (de -10 a +10). O LDA força os clientes normais a ficarem com médias próximas, por exemplo próximas a -3.5 e as fraudes com médias próximas entre si, por exemplo +4.2

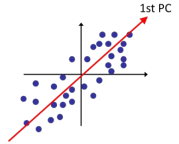
Aprendizado de Máquina - Não Supervisionado



- ➔ Redução de Dimensionalidade - LDA
  - ◆ Para que o LDA obtenha a máxima eficiência, ele assume algumas condições sobre os dados:
    - **Distribuição Normal**: As variáveis numéricas seguem uma distribuição gaussiana (curva de sino)
    - **Homocedasticidade**: As classes compartilham matrizes de covariância semelhantes
      - Uma matriz de covariância é uma tabela quadrada que mostra como duas ou mais variáveis variam juntas (se elas sobem e descem ao mesmo tempo, em sentidos opostos, ou se são independentes)
    - **Sem Multicolinearidade**: Variáveis extremamente correlacionadas entre si podem desestabilizar os cálculos da matriz inversa

Aprendizado de Máquina - Não Supervisionado

➔ Redução de Dimensionalidade - LDA

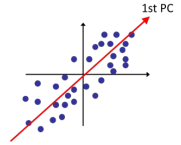


Característica	PCA	LDA
Tipo	Não supervisionado (ignora o rótulo y)	Supervisionado (exige o rótulo y)
Objetivo principal	Maximizar a variância global	Maximizar a separação entre classes
Nº de Componentes	Até min(N,P) atributos	Até K−1 (onde K é nº de classes)
Melhor uso	Compressão de dados sem perda de informação	Redução de dimensionalidade focada em classificação

- PCA (Não Supervisionado): "Não sei quem é fraude ou normal. Vou apenas tirar uma foto 2D onde os dados fiquem o mais espalhados possível."

- LDA (Supervisionado): "Eu SEI quem é fraude! Vou espremer e somar essas 30 colunas numa única nota LD1 de forma que o grupo Azul (Normal) fique de um lado e o grupo Vermelho (Fraude) fique do outro."

Classificação com dados do Kaggle

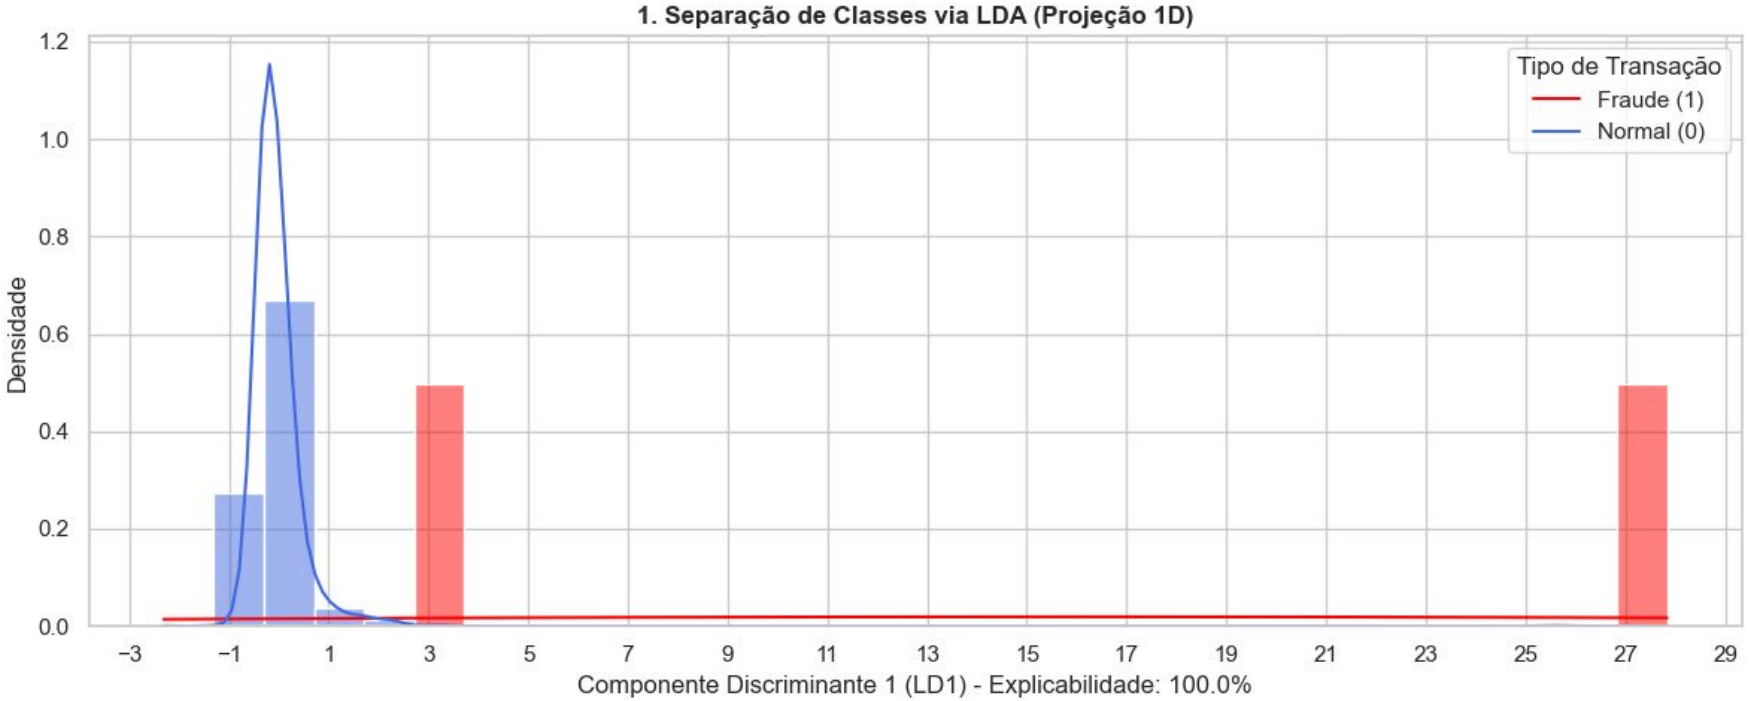


➔ *LDA*

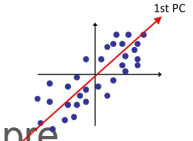
```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/Nsupervisionado_03.py
```

Classificação com dados do Kaggle

➔ *LDA*



Classificação com dados do Kaggle



- O eixo X é a nova componente criada pelo LDA para separar os dados, será sempre (*Num_Classes - 1*)

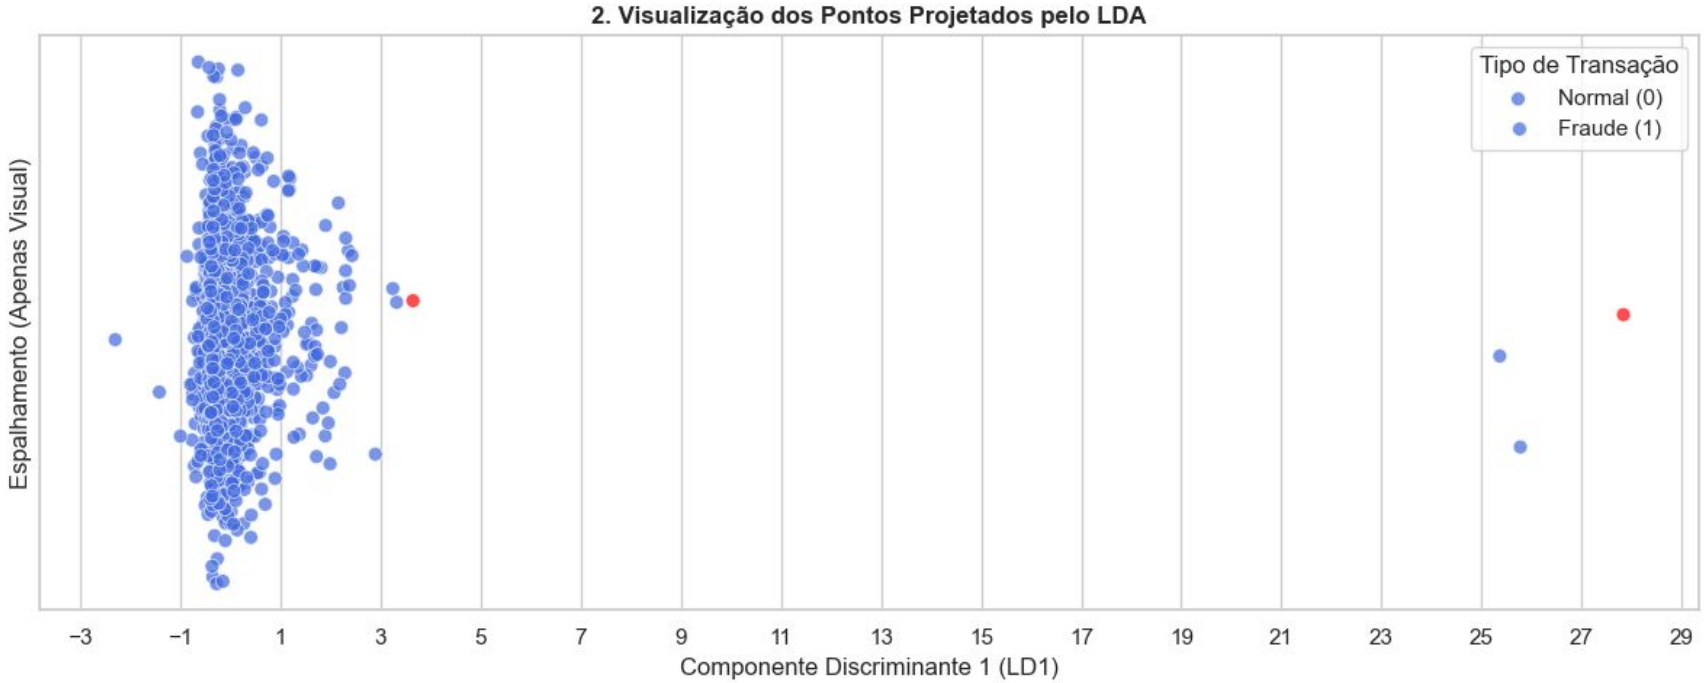
- As amostras de casos Normais estão todas agrupadas próximo ao valor 0(zero) do eixo X

- As amostras de Fraudes estão separadas (barras distantes)
  - Isto indica mais de um tipo de Fraude

- Como todas as amostras normais ficaram juntas, o gráfico aponta que qualquer amostra que fique na componente >= 3 é uma fraude, restando apenas classificar que tipo de fraude

Classificação com dados do Kaggle

➔ *LDA* - Similar ao Gráfico Anterior com a dispersão dos pontos



Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA

