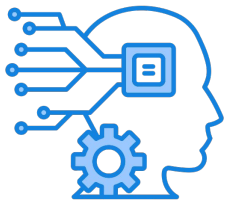
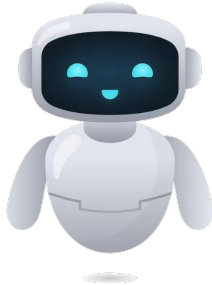
Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA



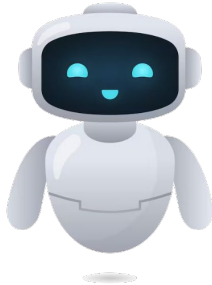
Aprendizado de Máquina - Aprendizado por Reforço



- Nos algoritmos estudados temos sempre dados históricos (DataSet)
  - Um conjunto $X \rightarrow Y$ onde:
    - X variável de entrada
    - Y variável alvo

Regressão		
Área	**Quartos**	**Preço**
100	3	500.000
120	4	650.000
80	2	350.000

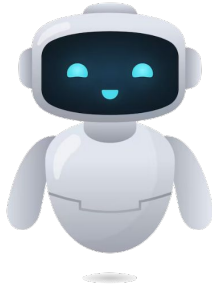
Aprendizado de Máquina - Aprendizado por Reforço



- Nos algoritmos estudados temos sempre dados históricos (DataSet)
  - Um conjunto $X \rightarrow Y$ onde:
    - X variável de entrada
    - Y variável alvo

Aprendizado Supervisionado			
Idade	**Oldpeak**	**FC máxima**	**Doença**
45	0.0	170	Não
50	0.5	160	Não
52	0.8	155	Não
60	2.0	130	Sim
65	2.5	120	Sim
70	3.0	110	Sim
X			Y

Aprendizado de Máquina - Aprendizado por Reforço



UFG INF
INSTITUTO DE INFORMÁTICA

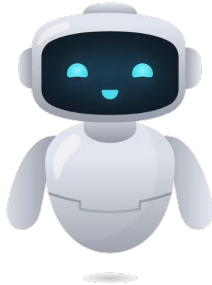
➔ Nos algoritmos estudados temos sempre dados históricos (DataSet)

- ◆ Um conjunto $X \rightarrow Y$ onde:
  - X variável de entrada
  - Y variável alvo

Aprendizado NÃO Supervisionado		
Idade	**Oldpeak**	**FC máxima**
45	0.0	170
50	0.5	160
52	0.8	155
60	2.0	130
65	2.5	120
70	3.0	110

X

Aprendizado de Máquina - Aprendizado por Reforço



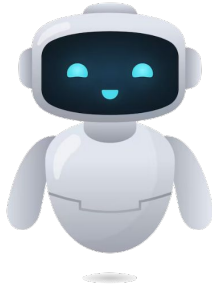
UFG INF INSTITUTO DE INFORMÁTICA

➔ Mas…

- Como treinar um robô para aprender uma ação quando não possuímos um dataset com todas as ações possíveis?

- Como ensinar um agente a jogar quando não sabemos previamente qual é a melhor jogada em cada situação?

Aprendizado de Máquina - Aprendizado por Reforço



Paradigma	Dados de Entrada	Objetivo
Supervisionado	X + Y	Prever Y
Não Supervisionado	X	Descobrir padrões
Reforço	Interação	Maximizar recompensa

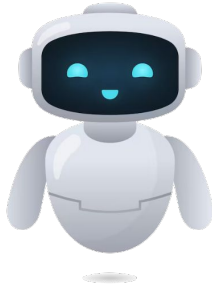
Aprendizado de Máquina Tradicional

DADOS
↓
MODELO
↓
PREDIÇÃO

Aprendizado por Reforço

AGENTE
↓ ação
AMBIENTE
↓
novo estado + recompensa
↓
AGENTE

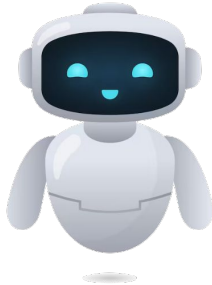
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

- Elementos principais no Aprendizado por Reforço
  - Agente
  - Ambiente
  - Estado
  - Ação
  - Recompensa
  - Política

Aprendizado de Máquina - Aprendizado por Reforço

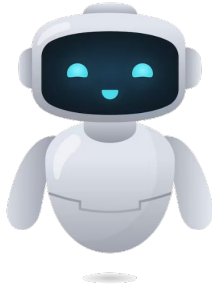


UFG INF
INSTITUTO DE INFORMÁTICA

- ➔ Agente
  - ◆ É o tomada-de-decisão, a "entidade" que toma ações para aprender uma tarefa
  - ◆ Não possui instruções explícitas de como agir; em vez disso, ele aprende por tentativa e erro, interagindo continuamente com o Ambiente

Elemento	🎮 Pac-Man	🚗 Carro Autônomo	📈 Algoritmo Financeiro	🐕 Adestrar um Cão
O Agente	**Código do Pac-Man**	**Sistema de IA do veículo**	**O bot/algoritmo de negociação**	**O cão**

Aprendizado de Máquina - Aprendizado por Reforço



- Ambiente
  - Todo o mundo externo com o qual o algoritmo (agente) interage. É o cenário, o sistema ou o problema que o agente precisa aprender a navegar ou resolver

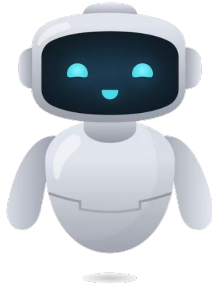
Elemento	🎮 Pac-Man	🚗 Carro Autônomo	📈 Algoritmo Financeiro	🐕 Adestrar um Cão
O Agente	Código do Pac-Man	Sistema de IA do veículo	O bot/algoritmo de negociação	O cão
O Ambiente	**Labirinto, fantasmas e pílulas**	**Rua, trânsito e pedestres**	**O mercado financeiro (bolsa de valores)**	**Casa e o dono**

Aprendizado de Máquina - Aprendizado por Reforço



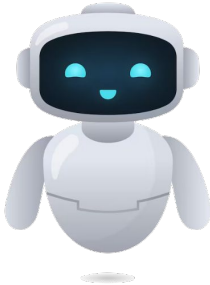
- Como o Ambiente se comunica com o Agente? A interação ocorre em um ciclo contínuo em três passos:
  - **Estado** (S_t): O ambiente apresenta ao agente a sua situação atual.
    - Exemplo: Em um jogo de xadrez, o estado é a posição exata de todas as peças no tabuleiro
  - **Ação** (A_t): O agente toma uma decisão e envia uma ação para o ambiente.
    - Exemplo: Mover o cavalo para a casa C3
  - **Novo Estado** (S_{t+1}) e Recompensa (R_{t+1}): O ambiente processa a ação, muda para um novo estado e devolve um sinal de recompensa (positivo, negativo ou neutro) para indicar se a ação foi boa ou ruim
    - Exemplo: O tabuleiro atualiza a nova posição das peças e dá +10 pontos se o movimento capturou uma peça adversária.

Aprendizado de Máquina - Aprendizado por Reforço



- Os ambientes podem ter características bem diferentes, o que altera a complexidade do problema:
  - **Determinístico vs. Estocástico**: O próximo estado é 100% previsível após uma ação (ex: xadrez) ou envolve incerteza e "sorte" (ex: pôquer, onde as cartas são sorteadas)?
  - **Totalmente Observável vs. Parcialmente Observável**: O agente consegue ver todo o ambiente (ex: tabuleiro aberto) ou só parte dele (ex: um robô em uma sala escura que só enxerga com o alcance dos seus sensores)?
  - **Discreto vs. Contínuo**: As ações/estados são passos contáveis (ex: mover para cima, baixo, esquerda) ou valores contínuos (ex: ajustar o ângulo do volante em 12,4 graus)?
- Em resumo, o ambiente define as regras do jogo, os desafios e o feedback que ensinam o agente a tomar decisões cada vez melhores.

Aprendizado de Máquina - Aprendizado por Reforço



- Estado
  - É uma fotografia instantânea de como o ambiente se encontra em um determinado momento. Ele representa todas as informações que o agente possui para decidir qual será sua próxima ação

Elemento	🎮 Pac-Man	🚗 Carro Autônomo	📈 Algoritmo Financeiro	🐕 Adestrar um Cão
O Agente	Código do Pac-Man	Sistema de IA do veículo	O bot/algoritmo de negociação	O cão
O Ambiente	Labirinto, fantasmas e pílulas	Rua, trânsito e pedestres	O mercado financeiro (bolsa de valores)	Casa e o dono
O Estado (*S*)	**Posição no labirinto**	**Velocidade e distância dos carros**	**Histórico de preços, indicadores (RSI, Média Móvel) e carteira atual**	**Ouvir a palavra "Senta!"**

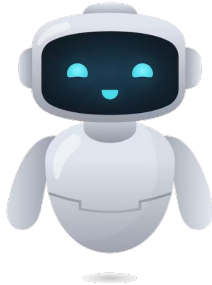
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

- Dependendo do problema, o estado pode ser representado por diferentes tipos de dados:
  - Em um videogame:
    - A matriz de pixels da tela atual (ou das últimas 4 telas para capturar o movimento/velocidade)
  - Em um robô:
    - Uma lista de números com: posição, velocidade, ângulo,
  - No mercado financeiro:
    - Um vetor com histórico de preços das ações, volume negociado, saldo disponível em conta e quantidade de ativos em carteira

Aprendizado de Máquina - Aprendizado por Reforço



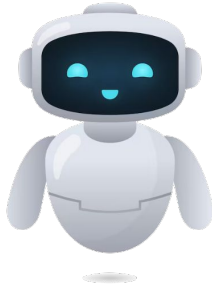
UFG INF
INSTITUTO DE INFORMÁTICA

➔ Ação

- ◆ Qualquer decisão, movimento ou escolha que o agente pode fazer para interagir com o ambiente em um determinado momento

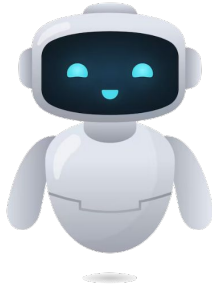
Elemento	🎮 Pac-Man	🚗 Carro Autônomo	📈 Algoritmo Financeiro	🐕 Adestrar um Cão
O Agente	Código do Pac-Man	Sistema de IA do veículo	O bot/algoritmo de negociação	O cão
O Ambiente	Labirinto, fantasmas e pílulas	Rua, trânsito e pedestres	O mercado financeiro (bolsa de valores)	Casa e o dono
O Estado (*S*)	Posição no labirinto	Velocidade e distância dos carros	Histórico de preços, indicadores (RSI, Média Móvel) e carteira atual	Ouvir a palavra "Senta!"
A Ação (*A*)	**Mover (cima, baixo, esq, dir)**	**Acelerar, frear ou virar**	**Comprar, Vender ou Manter o ativo**	**Sentar, latir ou correr**

Aprendizado de Máquina - Aprendizado por Reforço



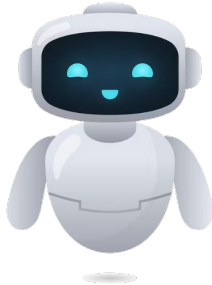
- As ações podem ser:
  - Explotação (*Exploitation*):
    - O agente escolhe a ação que ele já sabe que traz a maior recompensa com base na sua experiência passada
  - Exploração (*Exploration*):
    - O agente escolhe uma ação nova ou aleatória para testar o ambiente e descobrir se existe uma estratégia ainda melhor do que a atual
  - Exemplo:
    - Conheço um bom restaurante. Vou sempre voltar a ele para comer ou vou buscar conhecer novos restaurantes ?

Aprendizado de Máquina - Aprendizado por Reforço



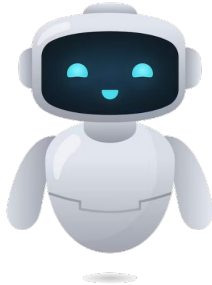
- Estratégia ϵ-*Greedy*
  - é um método simples e muito eficiente para resolver o dilema de Exploração vs. Explotação no Aprendizado por Reforço
  - Exemplo prático
    - Imagine que você vai almoçar fora:
    - ϵ = 0.1 (10% das vezes - Exploração): Você decide ir a um restaurante novo que nunca testou. Pode ser péssimo, mas você também pode descobrir o seu novo restaurante favorito da vida
    - ϵ = 0.9 (90% das vezes - Explotação): Você vai ao restaurante que você já conhece e sabe que a comida é ótima

Aprendizado de Máquina - Aprendizado por Reforço



- Estratégia ϵ-*Decay*
  - Se o agente mantiver um ϵ fixo para sempre, mesmo depois de aprender perfeitamente como resolver o ambiente, ele ainda tomará ações aleatórias inúteis
  -

Aprendizado de Máquina - Aprendizado por Reforço

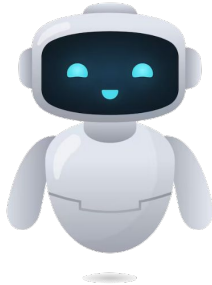


UFG INF
INSTITUTO DE INFORMÁTICA

- ➔ Recompensa
  - ◆ É o meio pelo qual dizemos ao agente o que é "bom" e o que é "ruim"

Elemento	🎮 Pac-Man	🚗 Carro Autônomo	📈 Algoritmo Financeiro	🐕 Adestrar um Cão
O Agente	Código do Pac-Man	Sistema de IA do veículo	O bot/algoritmo de negociação	O cão
O Ambiente	Labirinto, fantasmas e pílulas	Rua, trânsito e pedestres	O mercado financeiro (bolsa de valores)	Casa e o dono
O Estado (*S*)	Posição no labirinto	Velocidade e distância dos carros	Histórico de preços, indicadores (RSI, Média Móvel) e carteira atual	Ouvir a palavra "Senta!"
A Ação (*A*)	Mover (cima, baixo, esq, dir)	Acelerar, frear ou virar	Comprar, Vender ou Manter o ativo	Sentar, latir ou correr
A Recompensa (*R*)	**+10 (pílula) / -500 (fantasma)**	**+1 (andar seguro) / -1000 (colisão)**	**Lucro (+ R$) com a operação / Prejuízo (- R$) ou taxas de corretagem**	**Petisco (+1) / Nenhum petisco (0)**

Aprendizado de Máquina - Aprendizado por Reforço



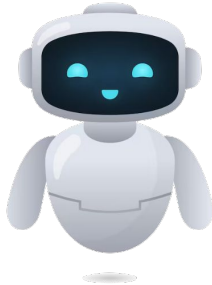
UFG INF INSTITUTO DE INFORMÁTICA

➔ Política

- Representada pela letra grega π é a "estratégia" ou o "manual de instruções" que o agente usa para decidir qual ação tomar ao se deparar com um determinado estado

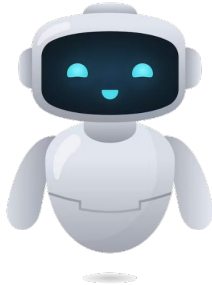
- O objetivo do algoritmo de Aprendizado por Reforço é encontrar a política ótima π, ou seja, a melhor estratégia possível que maximize as recompensas acumuladas a longo prazo

Aprendizado de Máquina - Aprendizado por Reforço



- ➔ Política
  - ◆ Determinística
    - Dado um estado, a política retorna sempre a mesma ação. Não há incerteza nem aleatoriedade
  - ◆ Estocástica
    - Dado um estado, a política retorna uma distribuição de probabilidade sobre todas as ações possíveis

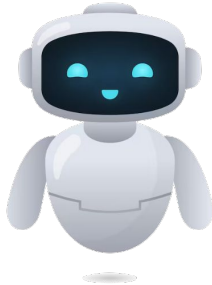
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

- Decisões e *Markov Decision Process* (MDP)
  - Nos modelos anteriormente estudados, uma previsão normalmente não modifica o próximo dado
    - Prever preço de uma casa (A previsão não altera o imóvel)
  - Em aprendizado por reforço, a decisão atual influencia as situações futuras
    - Jogo de Xadrez, Movimento de um robô

Aprendizado de Máquina - Aprendizado por Reforço

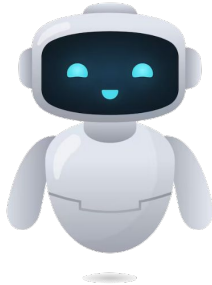


UFG INF INSTITUTO DE INFORMÁTICA

- ➔ Decisões e *Markov Decision Process* (MDP)
  - ◆ Se o estado, a ação e a recompensa são as "peças" do jogo, o MDP é a matemática que define as regras de como essas peças funcionam juntas ao longo do tempo

  - ◆ O MDP recebe esse nome porque se baseia na Propriedade de Markov:
    - "*O futuro é independente do passado, dado o presente.*"
    - Matematicamente, isso significa que para prever o próximo estado e a próxima recompensa, você só precisa saber o estado atual e a ação atual. Não importa todo o histórico de estados e decisões que o agente tomou até chegar ali

Aprendizado de Máquina - Aprendizado por Reforço

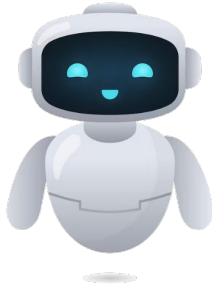


UFG INF
INSTITUTO DE INFORMÁTICA

➔ Decisões e *Markov Decision Process* (MDP)

- MDP é representado por uma tupla de 5 elementos: (S, A, P, R, γ)
  - S → Todos os estados possíveis que o ambiente pode assumir
  - A → Todas as ações possíveis que o agente pode executar
  - P → A probabilidade de ir do estado *s* para o estado *s'* ao tomar a ação *a*
  - R → O valor numérico esperado retornado ao transitar do estado *s* para *s'* através da ação *a*
  - γ → Um número entre 0 e 1 que define o quanto o agente valoriza recompensas futuras em comparação com recompensas imediatas
    - Se $\gamma \rightarrow 0$: O agente é "míope" (só quer saber de ganhos imediatos)
    - Se $\gamma \rightarrow 1$: O agente é "visionário" (dá alto valor às recompensas futuras)

Aprendizado de Máquina - Aprendizado por Reforço



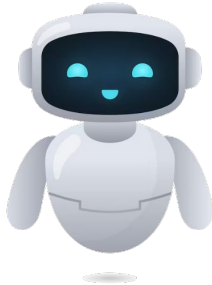
UFG INF INSTITUTO DE INFORMÁTICA

➔ Decisões e *Markov Decision Process* (MDP)

- Resolver um MDP significa encontrar uma política ótima que maximize o retorno acumulado

- A matemática do MDP nos garante que, se o problema puder ser formulado dessa forma, sempre existirá uma política ótima determinística que resolve o problema da melhor maneira possível

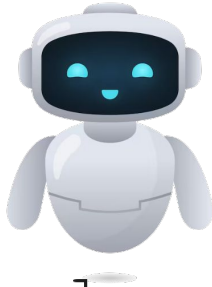
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF
INSTITUTO DE INFORMÁTICA

Aspecto	Aprendizado Supervisionado (Ex: Random Forest)	Aprendizado por Reforço (RL)
Origem dos Dados	Dataset pré-coletado e estático (passado)	Coletados em tempo real pelas ações do agente
O que é "Explorar"?	Testar diferentes combinações de hiperparâmetros (Grid/Random Search)	Testar diferentes ações desconhecidas no ambiente (ϵ-*Greedy*)
Quando ocorre a exploração?	Na etapa de ajuste e validação do modelo (*Tuning*)	Durante todo o ciclo de vida e treino do agente
Impacto da escolha	Escolher uma configuração ruim gera um modelo ruim no treino	Tomar uma ação ruim no treino faz o agente "sofrer" uma penalidade no ambiente

Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

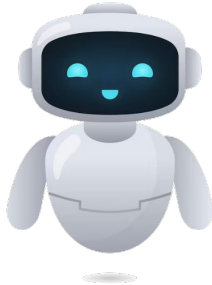
➔ Função de Valor de Estado: *V(s)*

$$V^{\pi}(s) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^{k} R_{t+k+1} \,\middle|\, S_t = s\right]$$

- A Função de Valor calcula o retorno total esperado a partir do estado *s*, assumindo que o agente continuará seguindo a sua política atual π

- O que ela pergunta: "*Estar neste estado s é bom ou ruim para mim no geral?*"
- Uso: Avaliar o quão promissora é uma situação/posição
  - Exemplo (Xadrez): *V(s)* avalia o tabuleiro atual. Estar em um estado onde você tem a Rainha e o Rei do oponente está encurralado tem um valor *V(s)* altíssimo, independentemente de qual peça você mover agora

Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

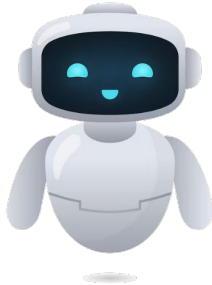
➔ Função Q (Valor de Ação-Estado): *Q(s, a)*

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty}\gamma^{k}R_{t+k+1} \,\middle|\, S_t = s, A_t = a\right]$$

- A Função Q (ou Action-Value Function) calcula o retorno total esperado se o agente estiver no estado *s*, tomar uma ação específica *a* agora, e só depois disso continuar seguindo a sua política π

- O que ela pergunta: "*Se eu estiver no estado s e tomar especificamente a ação a, qual será o meu resultado no futuro?*"
- Uso: Escolher ativamente a melhor decisão a ser tomada no momento
  - Exemplo (Xadrez): Q(s, a) avalia uma jogada específica. No estado atual *s*, qual é o valor de mover a Torre para a casa D8 (a_1) versus mover o Bispo para C4 (a_2)?

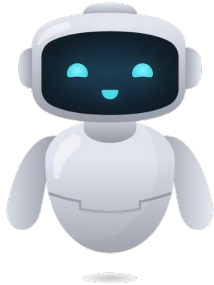
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF
INSTITUTO DE INFORMÁTICA

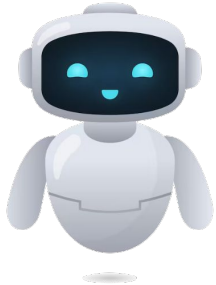
Característica	Função de Valor V(s)	Função Q Q(s,a)
Entrada	Apenas o Estado (s)	Estado (s) + Ação (a)
Foco	Avaliação do ambiente	Tomada de decisão direta
Pergunta	"Quão bom é estar aqui?"	"Quão bom é tomar esta ação aqui?"
Algoritmo famoso	Actor-Critic, Policy Evaluation	**Q-Learning, SARSA, DQN**

Aprendizado de Máquina - Aprendizado por Reforço



- Equação de Bellman
  - Criada pelo matemático Richard Bellman na década de 1950 e resolve um problema simples, mas fundamental:
  - como calcular o valor de uma decisão hoje pensando em todas as consequências futuras?
  - O segredo é quebrar uma decisão de longo prazo em duas partes:
    - Valor do Estado Atual = Recompensa Imediata + Valor do Próximo Estado

Aprendizado de Máquina - Aprendizado por Reforço

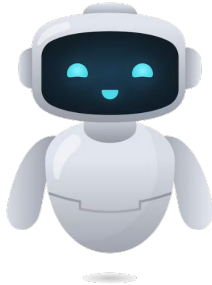


- Equação de Bellman
  - Imagine que você está em um jogo e quer saber o "valor" da sua posição atual:

    - **O que você ganha agora**: A pontuação imediata que o jogo te dá pela ação que acabou de fazer

    - **O que você ganha depois**: O valor estimado de estar na posição em que você vai parar no próximo segundo

Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

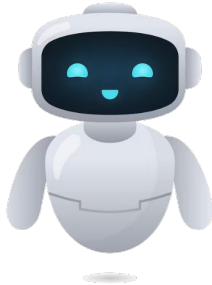
- Equação de Bellman
  - Para a Função de Valor:

$$V^{\pi}(s) = \sum_{a \in A} \pi(a \mid s) \sum_{s' \in S} P(s' \mid s, a) \left[R(s, a, s') + \gamma V^{\pi}(s') \right]$$

  - Para a Função de Q:

$$Q^{\pi}(s, a) = \sum_{s' \in S} P(s' \mid s, a) \left[R(s, a, s') + \gamma \sum_{a' \in A} \pi(a' \mid s') Q^{\pi}(s', a') \right]$$

Aprendizado de Máquina - Aprendizado por Reforço



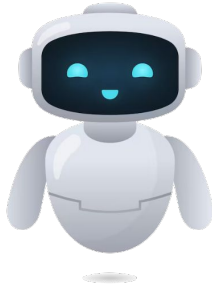
UFG INF
INSTITUTO DE INFORMÁTICA

➔ Equação de Bellman

- Sem a Equação de Bellman, um algoritmo de IA precisaria simular um jogo do início até o fim completo milhares de vezes para conseguir avaliar se uma ação no passo 1 foi boa ou ruim

- Com a Equação de Bellman, o agente pode atualizar o seu conhecimento a cada único passo, comparando o que ele esperava receber com o que ele realmente recebeu

Aprendizado de Máquina - Aprendizado por Reforço

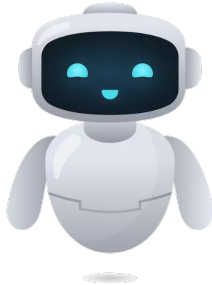


UFG INF
INSTITUTO DE INFORMÁTICA

➔ Q-Learning

- O Q-Learning é um dos algoritmos mais famosos e fundamentais do Aprendizado por Reforço
- Criado por Christopher Watkins em 1989
- O objetivo do Q-Learning é aprender a Função *Q(s, a)*, ou seja, descobrir uma tabela de valores que indica quão boa é cada ação *a* em cada estado *s*

Aprendizado de Máquina - Aprendizado por Reforço



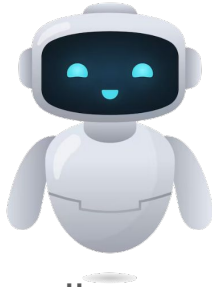
UFG INF INSTITUTO DE INFORMÁTICA

➔ Q-Learning - A tabela Q

- Em sua forma clássica, o Q-Learning guarda o conhecimento do agente em uma matriz simples chamada Q-Table:

  - Linhas: Representam os Estados (*s*)
  - Colunas: Representam as Ações (*a*)
  - Células: Guardam o Q-Value (valor Q), um número que representa o retorno futuro esperado para aquele par *(s, a)*

Aprendizado de Máquina - Aprendizado por Reforço

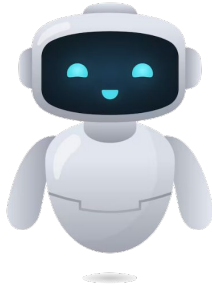


- Q-Learning - A tabela Q
  - Quando o robô está em cima da sujeira, ele consulta a tabela e escolhe a ação com maior valor Q: Aspirar (+10.0)

Estado (s)	Mover Frente (a1)	Virar Esquerda (a2)	Aspirar (a3)
Em frente ao sofá	1.2	0.5	-5.0
Em cima da sujeira	-1.0	-0.2	**+10.0**
Frente a uma parede	-10.0	**+3.5**	-1.0

  - A cada passo no tempo, o agente usa a Equação de Bellman para atualizar os valores da tabela com base na sua experiência real

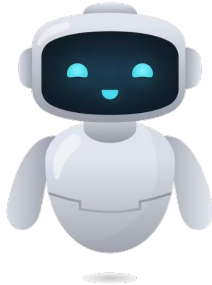
Aprendizado de Máquina - Aprendizado por Reforço



UFG INF
INSTITUTO DE INFORMÁTICA

- Q-Learning - A tabela Q - Algoritmo de Atualização
  - Inicialização: Preenche a Q-Table com zeros (ou valores aleatórios)
  - Observação: Lê o estado atual *s*
  - Escolha da Ação: Seleciona uma ação *a* usando a estratégia ϵ-*Greedy* (combina exploração e explotação)
  - Execução: Executa a ação no ambiente e observa a recompensa *R* e o novo estado *s′*
  - Atualização: Calcula o novo Q-Value *Q(s, a)*
  - Repetição: Define *s* = *s′* e repete até o ambiente terminar (fim do episódio)

Aprendizado de Máquina - Aprendizado por Reforço



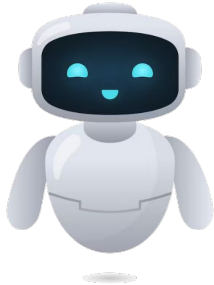
UFG INF
INSTITUTO DE INFORMÁTICA

➔ Relação com os modelos avançados de redes generativas

- O Aprendizado por Reforço (RL) e os Modelos Generativos não apenas se cruzam, mas alimentam e aprimoram um ao outro nas IAs mais avançadas da atualidade

- Enquanto os modelos generativos tradicionais aprendem a "imitar dados" (prever a próxima palavra ou pixel), o RL entra para guiar o processo de geração em direção a metas específicas, regras e preferências humanas

Aprendizado de Máquina - Aprendizado por Reforço



UFG INF INSTITUTO DE INFORMÁTICA

```
Caminho e nome do arquivo
     /Users/ronaldomartinsdacosta/am-env/python_scripts/reforco_01.py
```

Universidade Federal de Goiás
Instituto de Informática
Prof. Dr. Ronaldo Martins da Costa

UFG
INF
INSTITUTO DE INFORMÁTICA

